

Formation Modélisation statistique, l'essentiel

Correction des travaux pratiques

Matthieu Falce

8 et 9 octobre 2026

1 Prise en main

1.1 Ouverture de fichiers de données

Réponses :

1. les différentes options permettent de gérer différemment le fichier...
 - définir l'encodage permet de régler les problèmes avec les caractères spéciaux
 - on peut surcharger le type de séparateur et les séparateurs de chaînes
 - on peut choisir de *caster* le type d'une colonne (utile pour les dates)

Utiliser les mauvais paramètres peut rendre très compliquées les analyses suivantes.

2 Intuitions

2.1 Manipulation de lois statistiques

2.1.1 Contrôle qualité

Réponses :

1. les limites sont à 2 écarts-types de la moyenne → le cours nous indique que cela correspond à environ 5% des valeurs en dehors
 - si les valeurs n'étaient pas aussi bien tombées, on aurait pu calculer le Z-score et utiliser la table de la loi normale centrée réduite
 - ou on aurait pu utiliser les calculs pour retrouver les valeurs pour cette loi précise :
 - pour les éléments plus petits que 56mm : `LOI.NORMALE(56;60;2;VRAI)`
 - pour les éléments plus grands que 64mm : `1 - LOI.NORMALE(64;60;2;VRAI)`
2. oui, cf `corrections/testsHypotheses/manipulationLois/qualite.xls`
 - on génère des données issues de la loi normale donnée
 - on compte le nombre d'éléments en dehors des limites légales
3. dans ce cas la moyenne est centrée sur la norme, donc on n'a pas besoin d'y toucher
 - modifier une variance est a priori plus compliqué que changer une moyenne, car cela touche à la précision des procédés de fabrication (il faut identifier et réduire toutes les sources d'erreurs)
4. dans certains cas industriels, on peut vouloir décaler à gauche le plus possible, pour utiliser moins de matière

2.1.2 C'est presque ça !

Réponses :

1. ils correspondent à peu près à la taille de l'échantillon. Le nombre de degrés de liberté est égal à la taille de l'échantillon moins 1

- on note une asymptote qui tend vers une valeur dépendant de α
 - cela peut s'expliquer par le fait que l'on peut approximer la loi de Student par une loi normale dans les cas où l'échantillon a une taille infinie
- plus le risque est grand et plus l'intervalle de confiance est petit, donc la courbe pour un risque de 10% sera en dessous des autres courbes

2.2 La pièce truquée

Réponses :

- environ 170 fois sur 1 000 (valeur exacte 17,2 %). Une fois sur six n'a rien d'exceptionnel : on ne peut pas conclure qu'elle est truquée. Si on ne sait pas de quel côté, il faut aussi compter « au plus 3 piles » : 34 % (`binom.test(7, 10)`).
- avec 10 lancers, 9 piles (1,1 %) ou 8 piles (5,5 %) selon le risque qu'on accepte d'accuser une pièce normale : c'est le risque α . Avec 100 lancers, 59 piles suffisent (4,4 %), alors que 59 % est bien plus proche de 50 % que 8 sur 10 : avec plus de lancers, le hasard produit des écarts plus petits, et un petit écart devient détectable. 70 sur 100, c'est 4 fois sur 100 000.
- on ne sait pas. On n'a rien vu, ce n'est pas pareil : une pièce à 55 % de piles donne 5 sur 10 très souvent. Absence de preuve n'est pas preuve d'absence.
- environ 800 lancers pour la détecter 80 % du temps au risque de 5 % (formule de la taille d'échantillon d'une proportion, écart de 5 points autour de 50 %). Les petits effets coûtent cher.

C'est le raisonnement d'un test d'hypothèse : H_0 « la pièce est normale », une statistique (le nombre de piles), la probabilité d'un résultat au moins aussi extrême si H_0 est vraie (la p-value), un seuil fixé avant (α).

2.3 Le médicament contre la fièvre

Placebo : moyenne 38,90 °C, écart-type 0,46. Médicament : 38,40 °C, écart-type 0,50. Écart : 0,50 °C.

Réponses :

- 2 fois sur 1 000 en simulation. Si le médicament ne faisait rien, un écart de 0,5 °C entre deux groupes de 20 serait exceptionnel : on rejette H_0 , le médicament fait baisser la fièvre.
- test de Welch, celui de R par défaut : $t = 3,31$, 37,7 degrés de liberté, $p = 0,002$. C'est la probabilité d'un écart au moins aussi grand si le médicament ne faisait rien, la question 1 calculée au lieu d'être simulée. Ce n'est ni la probabilité que le médicament soit inutile, ni la taille de l'effet, qui est 0,5 °C.
- [0,19; 0,81] °C. L'intervalle ne contient pas 0 : même conclusion que $p < 5\%$. En plus, il donne la taille de l'effet, entre 0,2 et 0,8 °C, et laisse au médecin la question « est-ce que ça vaut le coup ? ».
- le même écart noyé dans quatre fois plus de variabilité : $t \approx 0,8$, $p \approx 0,4$, IC d'environ $-0,8$ à $+1,8$ °C. On ne pourrait plus conclure, avec le même effet. Ce qui compte, c'est l'écart rapporté à la variabilité et au nombre de patients.

2.4 Intervalles de confiance et p-value : intuitions

2.4.1 Comment-dire ?

Réponses :

- la notion de risque n'est pas indiquée. L'IC est un triplet (risque, valeur basse, valeur haute)

2.4.2 Intuition 1

Réponses :

- il manque les notions de risque associé à l'IC
- on connaît les risques demandés
 - IC3 contient IC1 qui contient IC2
 - risque IC3 (1%) < risque IC1 (5%) < risque IC2 (10%)

2.4.3 Intuition 2

Réponses :

1. les intervalles ne sont pas centrés sur la même moyenne
 - dans le cas de l'estimation de la moyenne, les coefficients sont issus de lois symétriques
 - les intervalles sont donc symétriques autour de la moyenne
2. non, il faut refaire les calculs

2.4.4 *p-value* : intuition

Réponses :

1. la *p-value* ne donne pas d'indications sur la valeur de l'effet. Dans ce cas, le plus gros échantillon sondé gagnait en moyenne 1589.17€ et le plus petit 22882.93€
2. il faudrait faire un test de comparaison de moyennes (test de Student par exemple, si les conditions d'utilisation sont respectées)

2.5 Quel test utiliser ?

Réponses :

1. On veut comparer des moyennes entre 2 groupes indépendants. Utiliser le test de Student.
2. On veut comparer des moyennes entre 4 groupes. Utiliser une ANOVA.
3. On veut comparer des moyennes pour des mesures répétées (avant et après un événement). Utiliser le test de Student pour échantillons appariés.
4. On veut comparer des proportions à une loi théorique (loi uniforme). Utiliser le test du χ^2 d'adéquation.
5. On veut tester l'association entre deux variables qualitatives. Utiliser le test du χ^2 d'indépendance.

2.6 Simulation

Voir le code de correction situé : `corrections/R/simulation.R`

3 Fil rouge : la boutique en ligne

3.1 Contexte

Les données sont générées par `corrections/filRouge/generationDonnees.py` (graine fixée). Les valeurs vraies, pour le débriefing :

- panier : loi log-normale, plus élevé pour le canal Email
- conversion : 3,1% pour A, 4,1% pour B (l'effet existe, le test est trop petit pour le voir)
- délai : Chronopost 1,7 j, Colissimo 3,2 j, Mondial Relay 4,0 j en moyenne (loi gamma, arrondie au jour)
- la satisfaction baisse avec le délai
- CA hebdo = $18\,000 + 4,2 \times \text{budget} + \text{bruit}$ (écart-type 2600 €)

Commandes R : `corrections/filRouge/filRouge.R` . Les chiffres des corrections viennent de `corrections/filRouge/ana`.

3.2 Étape 1 : décrire (Excel)

Panier (`montant_eur`, $n = 2000$) :

- moyenne 49,12 €, médiane 40,94 €, mode ≈ 30 €, écart-type 31,01 € (`ECARTYPE.STANDARD`)
- $Q_1 = 28,50$ €, $Q_3 = 60,40$ €, écart inter-quartiles 31,90 €

- minimum 5,83 €, maximum 271,33 €, 90^e centile 87,71 €, 99^e centile 168,21 €
- effectifs par classe : 342, 947, 400, 174, 111, 17, 9 (et 0 au-delà de 300 €)

Délais par transporteur (jours) :

	<i>n</i>	moyenne	médiane	écart-type
Chronopost	396	1,70	2	0,65
Colissimo	1002	3,21	3	1,27
Mondial Relay	602	3,97	4	1,58

Panier par canal (moyenne / médiane, €) : Email 55,44 / 45,66 ; SEA 49,07 / 40,76 ; SEO 48,05 / 40,52 ; Direct 47,32 / 39,30 ; Réseaux sociaux 44,58 / 37,42.

Réponses :

1. la distribution est asymétrique à droite (mode < médiane < moyenne, coefficient d'asymétrie 2,15) : quelques gros paniers tirent la moyenne. La médiane (41 €) décrit le client typique ; la moyenne (49 €) sert au chiffre d'affaires (CA = moyenne × nombre de commandes). Donner les deux, en disant lequel sert à quoi.
2. les 200 plus grosses commandes ($\geq 87,71$ €) font 24,3% du chiffre d'affaires
3. les boxplots ne se chevauchent presque pas : Chronopost est nettement plus rapide (1,7 j contre 3,2 et 4,0). Avec 400 à 1000 commandes par transporteur, le test de l'étape 4 ne fera que confirmer et chiffrer l'écart.
4. non : la satisfaction est une variable ordinale à 5 modalités. Un diagramme en bâtons des fréquences (1 : 1%, 2 : 10%, 3 : 35%, 4 : 40%, 5 : 13%) montre ce que la moyenne cache, par exemple 11% de mécontents (notes 1 et 2).

Fonctions Excel utiles : MOYENNE, MEDIANE, MODE.SIMPLE, ECARTYPE.STANDARD, QUARTILE.INC, CENTILE.INC, FREQUENCE (formule matricielle), NB.SI, MOYENNE.SI, SOMME.SI, tableau croisé dynamique.

3.3 Étape 2 : échantillonner (Excel, en groupe)

Population : $\mu = 49,12$ €, $\sigma = 31,01$ €.

Simulation de 2000 tirages de 30 commandes (`corrections/filRouge/analyse.py`) :

<i>n</i>	moyenne des moyennes	écart-type des moyennes	$\sigma/\sqrt{n}$	95% des moyennes entre
10	49,3	9,87	9,80	32,7 et 71,3
30	49,0	5,50	5,66	39,5 et 60,6
100	49,2	3,00	3,10	43,4 et 55,1

Réponses :

1. non : chaque échantillon donne une valeur différente, aucune n'est exactement 49,12. La moyenne d'un échantillon est elle-même une variable aléatoire.
2. ils sont proches (5,5 contre 5,66). L'écart-type des moyennes, l'*erreur standard*, vaut $\sigma/\sqrt{n}$: pour diviser l'erreur par 2, il faut 4 fois plus de clients.
3. les moyennes se répartissent presque symétriquement autour de 49 (asymétrie 0,35 pour $n = 30$, 0,09 pour $n = 100$) alors que les paniers sont très asymétriques (2,15). C'est le théorème central limite : la moyenne d'un échantillon suit une loi normale, quelle que soit la loi de départ, dès que n est assez grand.
4. dans la simulation, 93% des intervalles contiennent 49,12 : un peu moins que 95%, parce que le panier est très asymétrique et $n = 30$ petit. Dans une salle de 8 à 12 stagiaires, 0 ou 1 intervalle raté. Les 30 premières commandes du fichier donnent 56,73 € et $s = 43,73$ €, soit $IC_{95} = [40,4; 73,1]$: 8 € au-dessus de la vérité, et pourtant rien n'est faux.
5. on isole n dans la demi-largeur $e = z \frac{\sigma}{\sqrt{n}}$: $n = \left(\frac{1,96 \times 31,01}{e} \right)^2$, soit 148 clients pour ± 5 € et 924 pour ± 2 €.

3.4 Étape 3 : modéliser et prévoir (Excel)

Modèle : $CA = 17\,165 + 4,489 \times \text{budget}$, $r = 0,94$, $R^2 = 0,886$, $n = 52$. Erreur standard de la pente : 0,228 ; IC_{95} de la pente : [4,03; 4,95]. Écart-type résiduel $s_{res} = 2\,410$ €.

budget	CA prévu	IC_{95} du CA moyen	intervalle de prédiction à 95%
3 000 €	30 631 €	[29 835; 31 427]	[25 726; 35 536]
6 000 €	44 097 €	[42 935; 45 258]	[39 119; 49 075]
8 000 €	53 074 €	[51 092; 55 056]	[47 844; 58 304]

Réponses :

1. pente : les semaines à budget plus élevé ont fait en moyenne 4,49 € de CA de plus par euro de budget (entre 4,03 et 4,95 à 95%). C'est une association sur 52 semaines, pas une preuve que la publicité cause le CA : la saison peut tirer les deux. Ordonnée à l'origine : 17 165 € de CA à budget nul, mais aucune semaine n'a eu 0 € de budget, donc c'est une extrapolation.
2. 89% de la variabilité du CA d'une semaine à l'autre suit le budget ; les 11% restants (résidus, écart-type 2 410 €) viennent d'ailleurs : saison, météo, concurrence, hasard.
3. non : les résidus sont sans tendance autour de 0, à dispersion constante (test de normalité $p = 0,74$). Une courbure aurait signalé un rendement décroissant de la publicité ; un éventail, une incertitude qui grandit avec le budget.
4. 44 100 €, soit +13 500 € par rapport à 3 000 €, pour 3 000 € de dépense en plus. Pour une semaine donnée : entre 39 100 et 49 100 € (intervalle de prédiction).
5. on refuse, ou on encadre très fortement : le modèle a été ajusté entre 1 570 et 6 480 € de budget. Rien ne dit que la relation reste linéaire au-delà (saturation, enchères plus chères). C'est une extrapolation.
6. le premier est un paramètre de la population (le CA moyen sachant le budget), estimé par l'IC [42 935; 45 258], qui se resserre quand n grandit. Le second est une observation future, qui ajoute le bruit de la semaine : l'intervalle de prédiction [39 119; 49 075] ne descend jamais sous $\pm 2s_{res}$.

Dans R : `lm`, `summary`, `confint`, `predict(..., interval = "prediction")`, `plot(modele)` pour les résidus (voir `corrections/filRouge/filRouge.R`).

3.5 Étape 4 : tester (R)

Toutes les commandes R sont dans `corrections/filRouge/filRouge.R`.

3.5.1 Le test A/B

H_0 : le taux de conversion est le même pour A et B. H_1 : il est différent. Test du χ^2 d'indépendance sur un tableau 2×2 (équivalent à une comparaison de deux proportions).

	pas d'achat	achat	conversion
A	1968	63	3,10%
B	1886	83	4,22%

Réponses :

1. $\chi^2 = 3,2$, $p = 0,073$ (avec correction de continuité ; 0,061 sans). Au risque de 5%, on ne rejette pas H_0 : +1,1 point est du même ordre que ce que le hasard produit. IC₉₅ de $B - A$: $[-0,05; +2,28]$ points. À la direction : « B semble faire mieux mais ce n'est pas démontré ; l'écart réel est entre 0 et +2,3 points. Continuez le test. » Ne pas conclure « B ne marche pas » : les données ont été générées avec un vrai effet, 3,1% contre 4,1%.
2. 5 300 visites par version pour $\alpha = 5\%$ et une puissance de 80%, contre 2 000 ici (`power.prop.test(p1 = 0.03, p2 = 0.04, power = 0.8)`). À calculer avant de lancer le test.

3.5.2 Chronopost vaut-il son prix ?

Réponses :

1. échantillons non appariés (des commandes différentes). Test de Welch, celui de R par défaut : $t = 29,2$, $p < 10^{-100}$. Colissimo – Chronopost = 1,52 jour, IC₉₅ [1,41; 1,62]. La question n'est pas la p-value mais la taille de l'effet : 1,5 jour vaut-il le double du prix ?
2. $\chi^2 = 96,4$ à 2 degrés de liberté, $p < 10^{-20}$. Satisfaits (notes 4 et 5) : Chronopost 73%, Colissimo 52%, Mondial Relay 42%. Les effectifs attendus sous H_0 (210 satisfaits attendus chez Chronopost, 291 observés) montrent où est l'écart. Association, pas causalité : les clients qui choisissent Chronopost sont peut-être différents.

3.5.3 Les clients emailing dépensent-ils plus ?

Réponses :

1. ANOVA : $F = 5,81$, $p = 0,0001$, on rejette l'égalité des moyennes. Tukey : Email se distingue de tous les autres (+8,1 € vs Direct, $p = 0,005$; +10,9 € vs Réseaux sociaux, $p = 0,0002$; +6,4 € vs SEA, $p = 0,03$; +7,4 € vs

SEO, $p = 0,002$) ; aucune autre paire ne diffère. 85% des clients Email ne sont pas nouveaux : l'email parle aux clients fidèles.

Le montant n'est pas normal (étape 5) ; l'ANOVA sur $\log(\text{montant})$ ($F = 6,54$) et Kruskal-Wallis ($p = 0,0001$) donnent la même conclusion.

- Student à un échantillon contre 50 : $t = -1,27$, $p = 0,20$, IC_{95} [47,76; 50,48]. 50 est dans la fourchette, 48 aussi : « le panier moyen est de 49,1 €, entre 47,8 et 50,5 à 95% ; l'objectif de 50 € n'est ni atteint ni manqué de façon démontrable ».

3.6 Étape 5 : vérifier l'adéquation à un modèle (Excel ou R)

classe (€)	observé	attendu normale	attendu log-normale
[0, 25[	342	437	362
[25, 50[	947	586	889
[50, 75[	400	573	451
[75, 100[	174	303	177
[100, 150[	111	100	98
[150, 200[	17	1	18
[200, 300[	9	0	5

Réponses :

- fausse, et le signe moins le montre : un modèle normal prédit 5,7% de paniers négatifs (113 commandes sur 2000, dans la classe [0, 25[du tableau). La règle des 2 écarts-types ne vaut que pour une loi normale. Pour encadrer 95% des paniers, prendre les centiles observés [$P_{2,5}$; $P_{97,5}$].
- la log-normale : attendus et observés collent à 5–10% près, la normale se trompe d'un facteur 2 sur trois classes. χ^2 d'adéquation : $p \approx 0$ pour la normale, $p = 0,006$ pour la log-normale (rejetée aussi au sens strict : avec 2000 observations le test voit le moindre écart). Pour un non-statisticien, superposer l'histogramme et les deux courbes suffit.
- IC du panier moyen : pas de problème, théorème central limite (couverture 93% au lieu de 95% pour $n = 30$, 95% pour $n = 100$)
— ANOVA : robuste avec des groupes de 250 à 630 commandes, vérifié sur le log et par Kruskal-Wallis
— prévoir une commande : là, la loi compte. « 95% des paniers entre $\mu \pm 2\sigma$ » est faux ; utiliser les quantiles de la log-normale ou les centiles empiriques

Les hypothèses de normalité portent sur les moyennes ou les résidus, rarement sur la variable brute.

- oui : histogramme symétrique, Shapiro-Wilk $p = 0,74$, aucune structure dans le nuage résidus / prédits. L'intervalle de prédiction de l'étape 3 suppose un bruit normal autour de la droite ; des résidus asymétriques donneraient une fourchette fausse d'un côté.

3.7 Étape 6 : le rapport à la direction

Exemple de rapport.

Panier. Le panier médian est de 41 € : la moitié des commandes sont en dessous. Le panier moyen, qui sert au calcul du chiffre d'affaires, est de 49,1 € (entre 47,8 et 50,5 € à 95%). Les 10% de commandes les plus grosses font un quart du chiffre d'affaires. L'objectif de 50 € n'est ni atteint ni manqué de façon démontrable.

Page d'accueil. La version B a converti 4,2% des visiteurs contre 3,1% pour A. Sur 4000 visites, cet écart n'est pas démontré (il pourrait aller de 0 à +2,3 points). Recommandation : prolonger le test jusqu'à 5000 visites par version avant de décider.

Transporteurs. Chronopost livre 1,5 jour plus vite que Colissimo (entre 1,4 et 1,6, sur 1400 commandes). 73% des clients Chronopost se disent satisfaits, contre 52% pour Colissimo et 42% pour Mondial Relay. L'écart est démontré ; savoir s'il vaut le surcoût est une décision commerciale. Point inconnu : le lien peut être en partie dû au profil des clients qui choisissent Chronopost.

Publicité. Sur les 52 semaines, les semaines à budget élevé ont fait en moyenne 4,5 € de chiffre d'affaires de plus par euro de budget (entre 4,0 et 5,0). C'est une association observée ; pour démontrer que la publicité en est la cause, il faudrait faire varier le budget de façon contrôlée pendant quelques semaines. À 6000 € par semaine, le chiffre d'affaires attendu est de 44000 €, et une semaine donnée se situera entre 39000 et 49000 €. Nous ne pouvons rien dire au-delà de 6500 €, jamais testé.

Canal emailing. Les clients venus par email dépensent 7 à 11 € de plus par commande que les autres canaux, écart démontré. Ce sont surtout des clients déjà connus : l'email fidélise plus qu'il ne recrute.

Réponses :

1. « prouve » ne devrait apparaître nulle part (on rejette ou non une hypothèse, avec un risque). « Significatif » est acceptable si l'on précise le risque et que l'on donne aussi la taille de l'effet ; seul, il ne dit rien au lecteur. « La probabilité que B soit meilleure » est un contresens sur la *p-value* : on écrit plutôt « l'écart observé est compatible avec le hasard ».

4 Pour aller plus loin

4.1 Calcul d'effectifs cumulés croissants

On effectue les calculs :

- d'effectifs en utilisant la formule **FREQUENCE**. Attention, il s'agit d'une fonction matricielle, il faut la valider en utilisant **Alt-Maj-entrée**
- pour les effectifs cumulés croissants :
 - on utilise **FREQUENCE** en formule classique, sur une classe précise en décalant au fur et à mesure
 - on utilise les effectifs calculés précédemment et on les additionne avec la fonction **SOMME**

Voir les médias dans le dossier `corrections/descriptives/ecc/ecc.ods`

Réponses :

1. on peut effectuer un *scatter plot* (ecc en fonction de la classe)
2. on peut s'en servir. L'interprétation n'est pas forcément aisée, mais on peut voir s'il y a des différences de stagnation de salaires entre les deux entreprises et si les salaires semblent plus ou moins élevés.
3. il s'agit de la médiane

4.2 Étude de cas

Voir le code de correction situé : `corrections/descriptives/etudeDeCas.xlsx`

Réponses :

1. les *boxplots* des poids des bébés semblent contenir des éléments extrêmes

Réponses :

1. la variable expliquée correspond à celle que l'on cherche à mieux comprendre (à expliquer...). Dans ce cas, c'est le poids des bébés
2. pour visualiser l'impact de l'âge de la mère sur le poids des bébés à la naissance, nous pouvons effectuer une régression linéaire et regarder le coefficient de pente
3. le coefficient de corrélation entre les variables est très faible
 - cependant, on note une sorte de tendance
 - les individus exceptionnels (au bord) influent beaucoup sur la qualité de la régression, il faudrait les enlever pour voir l'impact sur la régression

4.3 Génération de données aléatoires

Pour les paramètres d'enregistrement sous LibreOffice : `corrections/descriptives/aleatoire/enregistrement.png`

Réponses :

1. les paramètres influent sur le type de fichier CSV généré (séparateurs, échappement des caractères spéciaux...)
2. le choix de la loi statistique est très important car il s'agit d'un modèle que l'on se fait sur la répartition des salaires.
 - Dans l'idéal, il faudrait que l'on reproduise la même distribution que dans une vraie entreprise.
 - Cela peut être fait à l'aide de plusieurs lois statistiques que l'on *mélange* (additions, soustraction...)
 - Il faut toujours garder à l'esprit les contraintes de notre domaine (les salaires sont positifs par exemple...)

4.4 Estimation et intervalles : les ampoules

4.4.1 Moyenne

Réponses :

- IC90 : [3962.437, 4015.372] – IC95 : [3957.180, 4020.629] – IC 99 : [3946.597, 4031.212]
 - on calcule la moyenne de l'échantillon : 3988.904
 - on calcule s sur l'échantillon : 111.6291
 - on calcule l'erreur standard $s/\sqrt{n}$: 15.78674
 - on regarde la valeur correspondant au quantile du risque dans la loi de t : $t_{1-\alpha/2}^{49}$
 - $\alpha = 0.10$: $t_{0.95}^{49} = 1.676551$ (dans Excel `LOISTUDENTINVERSE(0,1;49)`)
 - $\alpha = 0.05$: $t_{0.975}^{49} = 2.009575$ (dans Excel `LOISTUDENTINVERSE(0,05;49)`)
 - $\alpha = 0.01$: $t_{0.995}^{49} = 2.679952$ (dans Excel `LOISTUDENTINVERSE(0,01;49)`)
 - on fait les calculs : IC90 = $3988.904 \pm (1.676551 * 15.78674)$
 - on fait les calculs : IC95 = $3988.904 \pm (2.009575 * 15.78674)$
 - on fait les calculs : IC99 = $3988.904 \pm (2.679952 * 15.78674)$

4.4.2 Différence de moyennes

Réponses :

- IC95 de la différence des moyennes (nous - concurrent) = [-137.97062, -47.02895]
 - moyenne du concurrent : 4081.404
 - différence des moyennes (nous - concurrent) : -92.5
 - $\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} = 22.91264$
 - degrés de liberté : $(50 - 1) + (50 - 1)$
 - $\alpha = 0.05$: $t_{0.975}^{98} = 1.984531$
 - on fait le calcul : IC95 = $-92.5 \pm (1.984531 * 22.91264)$
- les ampoules du concurrent ont une durée de vie moyenne plus longue que les nôtres

4.4.3 Fréquence

Réponses :

- IC95 proportion ampoules cassées : [-0.005826784, 0.1258268]
 - $p = \frac{3}{50} = 0.06$
 - erreur standard : $\sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.06 \cdot 0.94}{50}} = 0.03358571$
 - centile 97.5 de la loi normale : $z_{0.975} = 1.959964$ (dans Excel `LOI.NORMALE.STANDARD.INVERSE(0,975)`)
 - on fait le calcul : IC95 = $0.06 \pm (1.959964 * 0.03358571)$
- la probabilité de panne négative est censée nous alerter : nous ne respectons pas les conditions d'approximation de la loi normale dans notre cas...
- R utilise une méthode plus robuste pour calculer les IC¹
- dans R : IC95 = [0.01562459, 0.17541874] (`prop.test(3, 50, conf.level=0.95)`)
- on peut utiliser `binom.confint(3, 50)` (`library(binom)`) dans R pour calculer les intervalles de confiance selon plusieurs méthodes possibles

4.5 Estimation de tailles d'échantillon

Réponses :

- on calcule la taille de l'échantillon avec la formule $n = \frac{z^2 \cdot \frac{p(1-p)}{e^2}}{1 + \frac{z^2 \cdot \frac{p(1-p)}{e^2}}{e^2 \cdot N}}$
 - $z = 2.58$ (valeur de la fonction de répartition pour 99%)

1. <https://stackoverflow.com/questions/41580829/>

- $N = 70000000$
 - $p = 0.5$
 - $e = 0.02$
 - donc $n = \frac{2.58^2 \cdot \frac{0.5 \cdot 0.5}{0.02^2}}{1 + \frac{2.58 \cdot 0.5 \cdot 0.5}{0.02 \cdot 70000000}} = 4161$ personnes à échantillonner
2. la formule se simplifie, on tend la population vers l'infini
- $n = z^2 \frac{p(1-p)}{e^2}$
 - $z = 2.58$ (valeur de la fonction de répartition pour 99%)
 - $p = 0.5$
 - $e = 0.02$
 - donc $n = 2.58^2 \cdot \frac{0.5 \cdot 0.5}{0.02^2} = 4161$ personnes à échantillonner
3. on prend $p = 0.3$ dans la formule précédente
- $n = z^2 \frac{p(1-p)}{e^2}$
 - $z = 2.58$ (valeur de la fonction de répartition pour 99%)
 - $p = 0.3$
 - $e = 0.02$
 - donc $n = 2.58^2 \cdot \frac{0.3 \cdot 0.7}{0.02^2} = 3495$ personnes à échantillonner
4. les échantillons de l'IFOP ont plutôt des tailles d'échantillons de 1000-2000 personnes, c'est le même ordre de grandeur, ils doivent avoir des contraintes de coût et connaître l'écart-type dans la population (un risque de 5% donne des tailles d'échantillons de 2400 personnes).

4.6 Test de Student (ou *t-test*)

Voir code dans `stats_inferentielles/test_student`

Réponses :

1. comparaison de la moyenne à 53mm, test de Student avec 5% de risque α : p-value = 0.07033 - IC = [52.95305, 54.15748] → on ne peut pas rejeter l'hypothèse nulle : la moyenne en sortie d'usine 1 est *compatible* avec 53mm (ce qui n'est pas la même chose que « égale à 53mm » : l'IC va de 52,95 à 54,16)
 - `t.test(cure_dent_usine_1, mu=53)`
2. comparaison de la moyenne à 53mm, test de Student avec 5% de risque α : p-value = $2.2 \cdot 10^{-16}$ - IC = [56.55227, 57.72858] → on rejette l'hypothèse nulle, la moyenne de la population n'est pas de 53mm
3. on fait un test de Student sur deux échantillons non appariés, avec un risque α de 5% on obtient : p-value = $6.214 \cdot 10^{-15}$ - IC : [-4.421763, -2.748557]
 - on rejette H_0 , il y a une différence sur la taille des cure-dents produits par les deux usines
 - dans R : `t.test(cure_dent_usine_1, cure_dent_usine_2)`
 - les variances des deux échantillons ne sont pas égales : le test de Student classique n'est pas adapté, mais R utilise par défaut la variante de Welch, qui ne suppose pas l'égalité des variances. Le test fait est donc le bon ; ici les deux versions donnent de toute façon le même résultat.

4.7 χ^2

Réponses :

1. on effectue un test du χ^2 pour savoir si le dé semble pipé ou pas
 - `chisq.test(table(des_comptage))`
 - la pvalue est 0.7985
 - on ne peut pas dire que le dé est truqué ; après, de là à miser toutes ses économies... le casino est toujours gagnant...

4.8 ANOVA

On ne peut pas effectuer 3 tests de Student directement entre les différentes modalités car on modifierait le risque α en faisant des tests répétés.

Réponses :

1. on effectue une ANOVA sur les données
 - `model = aov(fievre traitement, data=total)`
 - `anova(model)`
 - pvalue : $8.282 \cdot 10^{-10}$, inférieure au seuil de 5%, on rejette H_0 , il y a un effet du médicament sur la fièvre
2. on ne refait *pas* des tests de Student deux à deux (on vient de dire pourquoi) : on utilise un test *post-hoc* qui contrôle le risque global, le test de Tukey
 - `TukeyHSD(model)` (ou `HSD.test` de la bibliothèque `agricolae`)
 - les trois groupes sont significativement différents deux à deux (lettres a, b, c) : témoin 39,88 °C, dose 500 mg 39,10 °C, dose 1000 mg 38,27 °C
 - la dose à 1000 mg est la plus efficace, avec un écart de 0,8 °C par rapport à 500 mg

4.9 Étude de cas

Voir le code de correction situé : `corrections/R/statsDescriptives.R`