

Quelle question, quel test, quelle phrase ?

Modélisation statistique, l'essentiel

Avant de calculer quoi que ce soit : **quelle est la question ? quel type de variables ? combien de groupes ? les mesures sont-elles indépendantes ?** Puis choisir la ligne, calculer, et écrire la phrase avec sa fourchette et son effectif.

La question métier	Variables	Outil	Excel	R	La phrase du rapport
Quel chiffre unique donner ?	1 quantitative	moyenne, médiane, quantiles, écart-type	MOYENNE, MEDIANE, QUARTILE.INC, ECARTYPE.STANDARD	summary, sd	« Le panier médian est de 41 € (la moitié des commandes en dessous) ; le panier moyen, qui sert au CA, est de 49 €. »
Quelle précision sur cette moyenne ?	1 quantitative, n observations	IC de la moyenne : $\bar{x} \pm t s / \sqrt{n}$	LOI.STUDENT. INVERSE.BILATERALE (0,05;n-1)	t.test(x)	« 49,1 € en moyenne, entre 47,8 et 50,5 à 95 % ($n = 2000$). »
Quelle précision sur ce pourcentage ?	1 binaire, n observations	IC d'une proportion (si $np \geq 5$)	$p \pm 1,96 \sqrt{p(1-p)/n}$	prop.test(k, n)	« 4,2 % de conversion, entre 3,3 et 5,1 % ($n = 1969$). »
Combien de données me faut-il ?	précision voulue e , variabilité σ	$n = (z\sigma/e)^2$; proportion : $n = z^2 p(1-p)/e^2$	calcul direct	power.t.test, power.prop.test	« Pour connaître le panier moyen à ± 5 €, il faut 150 clients ; à ± 2 €, 920. »
Cette moyenne est-elle différente d'un objectif ?	1 quantitative, 1 valeur cible	Student à un échantillon	T.TEST n'existe pas pour ce cas : passer par l'IC	t.test(x, mu=50)	« L'objectif de 50 € n'est ni atteint ni manqué de façon démontrable (IC 47,8 à 50,5). »
Deux groupes ont-ils la même moyenne ?	1 quantitative, 1 binaire, groupes distincts	Student (Welch)	T.TEST(a;b;2;3)	t.test(x ~ groupe)	« Chronopost livre 1,5 jour plus vite que Colissimo (entre 1,4 et 1,6). »
Avant / après sur les mêmes individus ?	2 mesures par individu	Student apparié (Wilcoxon signé si non normal)	T.TEST(avant;apres;2;1)	t.test(a, b, paired=TRUE)	« Le traitement fait baisser la fièvre de 0,8 °C en moyenne (0,5 à 1,1). »
Plus de deux groupes ont-ils la même moyenne ?	1 quantitative, 1 qualitative à k niveaux	ANOVA puis Tukey (Kruskal-Wallis si non normal)	Utilitaire d'analyse : « Anova : un facteur »	aov, TukeyHSD	« Le canal joue ($p < 0,001$) : seul Email se distingue, avec 6 à 11 € de plus par commande. »
Deux pourcentages sont-ils différents ? (A/B test)	2 binaires (version, achat)	χ^2 sur un tableau 2×2	CHISQ.TEST(observé;attendu)	chisq.test(table(v, a))	« B convertit 4,2 % contre 3,1 % ; l'écart n'est pas démontré (de 0 à +2,3 points), poursuivre le test. »
Deux variables qualitatives sont-elles liées ?	2 qualitatives	χ^2 d'indépendance	CHISQ.TEST	chisq.test(table(x, y))	« La satisfaction dépend du transporteur : 73 % de satisfaits chez Chronopost contre 42 % chez Mondial Relay. »
Ces effectifs suivent-ils la loi attendue ?	1 qualitative, proportions théoriques	χ^2 d'adéquation	CHISQ.TEST	chisq.test(obs, p=...)	« Rien ne permet de dire que le dé est truqué ($p = 0,80$). »
Comment y varie-t-il avec x ? Que prévoir ?	2 quantitatives	régression linéaire, R^2 , résidus	PENTE, DROITEREG, PREVISION.LINEAIRE	lm, summary, predict	« Les semaines à 1 € de budget de plus ont fait 4,5 € de CA de plus (4,0 à 5,0) ; à 6 000 €, on attend 44 k€, entre 39 et 49 k€ pour une semaine donnée. »
Ces deux variables bougent-elles ensemble ?	2 quantitatives	corrélation r (entre -1 et 1)	COEFFICIENT.CORRELATION	cor, cor.test	« Délai et satisfaction sont liés ($r = -0,5$) ; cela ne dit pas lequel cause l'autre. »
Cette variable suit-elle une loi normale ?	1 quantitative	histogramme, QQ-plot, χ^2 d'adéquation	LOI.NORMALE.N pour les attendus	qqnorm, shapiro.test	« Le panier n'est pas normal (asymétrique) : on décrit avec la médiane et les centiles, pas avec $\mu \pm 2\sigma$. »

Les réflexes avant le test

- regarder les données (histogramme, boxplot) *avant* de tester
- écrire H_0 (« il n'y a pas de différence ») et le risque α (5 % par défaut) *avant* de voir le résultat
- bilatéral par défaut ; unilatéral seulement si le sens était décidé à l'avance
- groupes distincts ou mêmes individus ? (apparié)
- les résidus, pas la variable brute, doivent être à peu près normaux

Les réflexes après le test

- donner l'effet avec sa fourchette, pas seulement la p -value
- $p > 0,05$: « pas vu », jamais « il n'y a rien » ; regarder la largeur de l'IC
- $p < 0,05$ avec un effet minuscule : significatif mais sans intérêt
- association $\neq$ cause : une troisième variable peut tirer les deux
- pas d'extrapolation hors de la plage observée