

Le vocabulaire du rapport d'analyse

Modélisation statistique, l'essentiel

Un rapport basé sur les faits dit trois choses pour chaque chiffre : **la valeur**, **sa précision** (fourchette et effectif), **ce qu'on en conclut** en distinguant le *démontré*, le *probable* et l'*inconnu*.

Ce qu'on écrit, ce qu'on n'écrit pas

À bannir	À écrire à la place
« Le test prouve que... »	« Les données rejettent l'hypothèse d'absence d'effet au risque de 5 %. » La statistique ne prouve jamais, elle rend une hypothèse peu crédible.
« La différence est significative. » (seule)	« B convertit 1,1 point de plus que A (de -0,1 à +2,3), écart compatible avec le hasard sur 4 000 visites. » Toujours l'effet, sa fourchette, l'effectif.
« Il n'y a pas de différence. » ($p > 0,05$)	« Nous n'avons pas mis en évidence de différence ; l'écart réel se situe entre 0 et 2,3 points. » Absence de preuve n'est pas preuve d'absence.
« Il y a 95 % de chances que la vraie valeur soit dans l'intervalle. »	« Entre 47,8 et 50,5 € à 95 % de confiance. » Le 95 % porte sur la méthode ; un intervalle donné contient la vraie valeur ou pas.
« La probabilité que B soit meilleure est de 93 %. » (lecture de $1 - p$)	« Si les deux pages convertissaient pareil, un tel écart se verrait 7 fois sur 100. » La p -value n'est pas la probabilité de l'hypothèse.
« La publicité rapporte 4,5 € par euro. »	« Les semaines à budget plus élevé ont fait 4,5 € de CA de plus par euro (4,0 à 5,0). Pour démontrer un effet de la publicité, il faudrait faire varier le budget de façon contrôlée. »
« 95 % des paniers sont entre -13 et 111 € ($\mu \pm 2\sigma$). »	« 95 % des paniers sont entre 12 et 130 € (centiles 2,5 et 97,5). » La règle des 2 écarts-types ne vaut que pour une loi normale.
« Le panier moyen est de 49 €. » (seul)	« Le panier médian est de 41 € ; le panier moyen, qui sert au chiffre d'affaires, est de 49 € ($n = 2000$). » Dire lequel sert à quoi.
« À 12 000 € de budget, le CA sera de 71 k€. »	« Le modèle a été ajusté entre 1,6 et 6,5 k€ ; au-delà, nous ne pouvons rien affirmer. » Pas d'extrapolation.
« L'échantillon est significatif. »	« L'échantillon compte 30 clients tirés au hasard ; la précision sur la moyenne est de ± 11 €. » Une taille n'est pas significative, elle donne une précision.
« Les clients Chronopost sont satisfaits grâce à la rapidité. »	« La satisfaction est liée au transporteur (73 % contre 42 %). Le lien peut venir en partie du profil des clients qui choisissent Chronopost. »

La phrase type

[l'indicateur] vaut [valeur] (entre [bas] et [haut] à 95 %, $n =$ [effectif]). [Conclusion en un verbe prudent] : est compatible avec, se distingue de, n'a pas pu être mis en évidence.

Trois niveaux de certitude

- **démontré** : $p < \alpha$ et effet d'une taille qui compte, IC loin de zéro
- **probable** : IC qui frôle zéro, ou effet visible mais peu de données
- **inconnu** : pas mesuré, hors plage, ou lien possible avec une variable non observée

Structure d'un rapport d'une page

1. **La question** telle que la direction l'a posée, en une ligne.
2. **Les données** : d'où elles viennent, combien, sur quelle période, ce qui manque.
3. **Le résultat** : une phrase type par question, avec sa fourchette.
4. **Ce qui reste incertain**, et ce qu'il faudrait mesurer pour trancher.
5. **La recommandation**, en une phrase, avec la décision qu'elle engage.

Relecture finale

- chaque chiffre a sa fourchette et son effectif ?
- « prouve », « significatif » seul, « probabilité que » : supprimés ?
- un lecteur pressé comprend la première phrase de chaque paragraphe ?