

Formation Modélisation statistique, l'essentiel

Sujet des travaux pratiques

Matthieu Falce

8 et 9 octobre 2026

1 Prise en main

1.1 Ouverture de fichiers de données

Objectifs : 1) Rappels 2) Découvrir la notion de fichiers CSV 3) Paramètres d'ouverture des CSV

Concepts : 1) Connaissances de base d'Excel

Excel peut ouvrir une multitude de types de fichiers différents. Parmi cela, les plus communs pour échanger des données sont les CSV (*comma-separated values*).

Problème, CSV n'est pas un standard, il peut fortement varier (type de séparateur, *escaping* des chaînes, ...)

Étapes :

1. ouvrez les fichiers `medias/descriptives/ouvertureFichiers/simple.csv` et ses voisins
2. affichez leur contenu

Questions :

1. quel est l'impact des différentes options d'ouverture ?

2 Intuitions

2.1 Manipulation de lois statistiques

Objectifs : 1) découvrir les lois statistiques classiques 2) manipuler les fonctions de répartition

2.1.1 Contrôle qualité

Mon usine de fabrication de cure-dents a mis en place un contrôle qualité rigoureux.

On estime que la longueur d'un cure-dent suit une loi normale, centrée sur 60mm, écart-type de 2mm, c'est-à-dire $l \sim \mathcal{N}(60, 2^2)$

La législation nous impose d'avoir des cure-dents d'une taille comprise entre 56 et 64 mm.

Questions :

1. quelle prédiction pouvons-nous faire sur le nombre de cure-dents qui ne vont pas respecter les conditions légales ?
2. peut-on retrouver ce résultat en faisant une simulation ?
3. si l'on pouvait choisir, vaut-il mieux modifier la moyenne ou la variance ? Quelles implications pratiques cela représente-t-il dans chaque cas ?
4. va-t-on forcément placer la moyenne au centre de l'intervalle autorisé ?

2.1.2 C'est presque ça !

Nous allons retrouver l'origine des approximations de calcul des IC de moyennes données en cours pour les différentes tailles d'échantillons.

Étapes :

1. calculez les valeurs d'une loi de Student pour un risque de 5% en variant les degrés de liberté
2. recommencez pour les risques de 1% et 10%
3. effectuez la représentation graphique adaptée pour représenter les valeurs de la loi pour le risque à 5% en fonction du degré de liberté

Questions :

1. que représentent les degrés de liberté de la loi de Student dans le cas de l'IC de la moyenne
2. comment se comportent les courbes ?
3. intuitivement où placeriez-vous les courbes des autres risques par rapport à celle de 5% ?

2.2 La pièce truquée

Objectifs : 1) raisonner « comme si » l'hypothèse était vraie, et regarder si ce qu'on observe est courant ou exceptionnel 2) voir que le seuil de décision dépend du nombre d'observations 3) savoir ce qu'on peut conclure, et ce qu'on ne peut pas

Je lance une pièce 10 fois et j'obtiens 7 piles. Est-elle truquée ?

Étapes :

1. chacun lance une vraie pièce 10 fois (ou, sans pièce, 10 cellules `=ALEA.ENTRE.BORNES(0;1)`) et note son nombre de piles dans le tableau partagé
2. dans Excel, simulez 1 000 séries de 10 lancers d'une pièce *normale* : 10 colonnes de `=ALEA.ENTRE.BORNES(0;1)` sur 1 000 lignes, une colonne `SOMME` par ligne, puis `=NB.SI(plage;">=7")/1000`. En R : `mean(rbinom(1000, 10, 0.5) >= 7)`
3. comparez avec la valeur exacte : Excel `=1-LOI.BINOMIALE.N(6;10;0,5;VRAI)`, R `1-pbinom(6, 10, 0.5, lower.tail = FALSE)`
4. recommencez avec 100 lancers et 70 piles

Questions :

1. 7 piles sur 10 : sur vos 1 000 séries, combien de fois une pièce normale fait-elle au moins 7 piles ? Que concluez-vous ?
2. à partir de combien de piles sur 10 diriez-vous « truquée » ? Et sur 100 lancers ? Qu'est-ce qui a changé ?
3. vous obtenez 5 piles sur 10 : la pièce est-elle normale ?
4. pour aller plus loin : une pièce qui tombe sur pile 55 % du temps, combien de lancers pour s'en apercevoir ?

2.3 Le médicament contre la fièvre

Objectifs : 1) refaire le raisonnement de la pièce truquée sur une différence de moyennes 2) voir ce que le hasard du tirage produit comme écart entre deux groupes 3) relier simulation, intervalle de confiance et test

40 malades ont été répartis au hasard en deux groupes de 20. Le premier a reçu un placebo, le second le médicament. On a mesuré leur température le lendemain : `medias/testsHypotheses/fievre.csv` .

Étapes :

1. calculez la moyenne et l'écart-type de chaque groupe, et l'écart entre les deux moyennes
2. faites *comme si* le médicament ne faisait rien : les 40 températures viennent alors d'une seule et même population. Dans Excel, copiez les 40 valeurs, mélangez-les (une colonne `=ALEA()` à côté, puis tri), prenez les 20 premières comme « placebo » et les 20 autres comme « médicament », et notez l'écart des moyennes

3. recommencez une vingtaine de fois (ou 1000 fois en R : `replicate(1000, {g = sample(temp); mean(g[1:20]) - mean(g[21:40])})`) et regardez quels écarts le hasard du tirage produit
4. calculez l'intervalle de confiance à 95 % de la différence des moyennes et faites le test de Student : Excel `=T.TEST(placebo;medicament;2;3)`, R `t.test(temperature ~ groupe, data = fievre)`

Questions :

1. sur vos tirages « comme si le médicament ne faisait rien », combien de fois obtenez-vous un écart d'au moins 0,5 °C, dans un sens ou dans l'autre ?
2. que vaut la p-value ? Que dit-elle, et que ne dit-elle pas ?
3. que vaut l'intervalle de confiance de la différence ? Est-ce que 0 en fait partie ? Quel lien avec la p-value ?
4. avec les mêmes moyennes, mais des températures qui varient de 2 °C d'un patient à l'autre au lieu de 0,5 °C, que se passerait-il ?

2.4 Intervalles de confiance et p-value : intuitions

Objectifs : 1) comprendre ce qu'est (et n'est pas) un intervalle de confiance 2) comprendre ce qu'est (et n'est pas) une p-value

2.4.1 Comment-dire ?

Nous travaillons dans une usine de fabrication de cure-dents. Nous avons estimé l'intervalle de confiance de la moyenne de la longueur de nos cure-dents à [55-65] mm.

Questions :

1. qu'est-ce qui ne va pas avec cette affirmation ?

2.4.2 Intuition 1

J'ai demandé au stagiaire de calculer les intervalles de confiance à 90-95-99% pour la moyenne de la longueur de nos cure-dents.

Il m'a donné les résultats suivants :

- IC1 : [51.4 – 53.2] mm
- IC2 : [51.6 – 53] mm
- IC3 : [51.1 – 53.5] mm

Questions :

1. qu'est-ce qui ne va pas avec ces résultats ?
2. peut-on quand même régler ce problème ?

2.4.3 Intuition 2

J'ai demandé à un autre stagiaire de calculer les intervalles de confiance à 90-95-99% pour la moyenne de la longueur de nos cure-dents.

Il m'a donné les résultats suivants :

- IC1 : [50.5 – 52.3] mm
- IC2 : [49.5 – 53.1] mm
- IC3 : [51.1 – 53.5] mm

Questions :

1. qu'est-ce qui ne va pas avec ces résultats ?
2. peut-on quand même régler ce problème ?

2.4.4 *p-value* : intuition

J'ai sondé deux échantillons différents (40 et 400 personnes) en leur demandant leur salaire. J'ai voulu voir si les moyennes des salaires dans les deux populations étaient supérieures à 1500€. J'ai donc effectué un test de Student sur chacune de mes populations.

Voilà les p-value que j'obtiens :

- P1 : p-value < 2.2e-16
- P2 : p-value = 3.388e-13

Questions :

1. est-ce que je peux dire quelle est la sous-population avec le meilleur salaire ?
2. si oui, laquelle ? Si non, que puis-je faire ?

2.5 Quel test utiliser ?

Concepts : 1) tests statistiques 2) inférence statistique

Dans ces différents cas, quels sont les tests à employer pour vérifier les hypothèses que nous formulons ?

Questions :

1. J'ai fait passer un examen à 2 classes d'étudiants. Je voudrais voir s'il y a une classe meilleure que l'autre.
2. Je fais pousser des plants de maïs dans 4 parcelles différentes, j'utilise un engrais spécifique par parcelle. Je voudrais savoir si l'engrais a une influence sur la production.
3. J'ai un groupe de malades avec de la fièvre, je leur donne un médicament. Je voudrais savoir s'il a un effet significatif.
4. J'ai accès à un sous-ensemble des données anonymisées des cartes nationales d'identité, il est noté la couleur des yeux. La proportion de personnes dans chaque modalité est-elle équirépartie ?
5. J'ai fait un questionnaire en ligne en demandant aux gens leur couleur préférée entre le vert et le mauve et leur genre. Je voudrais savoir s'il y a un lien entre couleur préférée et genre ?

2.6 Simulation

Objectifs : 1) apprendre à manipuler R 2) mieux appréhender la notion de risque statistique

2.6.1 Risque statistique

Concepts : 1) boucles en R (**for**) 2) comparaison à une valeur en R (**if**)

Nous allons explorer la notion de risque statistique α grâce à la facilité avec laquelle on peut générer des données aléatoires *connues à l'avance*. Nous avons rarement ce luxe en pratique (estimations).

Étapes :

1. générez 30 valeurs aléatoires issues d'une loi normale centrée réduite
2. testez la nullité de la moyenne de la population à l'aide d'un test de Student avec des risques de 1-5-10%
3. répétez l'opération 1000 fois en comptant la significativité des résultats

Questions :

1. les résultats sont-ils cohérents avec la théorie ?

Nous allons à présent explorer le risque β .

Étapes :

1. générez 30 valeurs aléatoires issues d'une loi normale centrée sur 2 et de variance 1
2. testez la nullité de la moyenne de cet échantillon à l'aide d'un test de Student avec des risques de 1-5-10%
3. répétez l'opération 1000 fois en comptant la significativité des résultats

Questions :

1. quel est l'impact de l'effet sur le résultat (moyenne de la loi à 20) ?
2. quel est l'impact du nombre d'individus ?

3 Fil rouge : la boutique en ligne

3.1 Contexte

Vous venez d'être recruté comme analyste chez *Maison Verdier*, une boutique en ligne de thés et d'accessoires. La direction vous pose, en vrac, les questions qu'elle se pose depuis des mois :

- quel est notre panier moyen ? Le chiffre change selon la personne qui le calcule...
- la nouvelle page d'accueil (version B) fait-elle vraiment mieux que l'ancienne ?
- Chronopost coûte deux fois plus cher que Colissimo : les clients le remarquent-ils ?
- si on double le budget publicitaire la semaine prochaine, quel chiffre d'affaires attendre ?
- les clients venus par l'emailing dépensent-ils plus que les autres ?

Le même cas nous accompagnera pendant les deux jours. À chaque étape, on ajoute un outil ; à la fin, on rédige le rapport pour la direction.

Trois fichiers (séparateur ;, décimale ., ils s'ouvrent directement dans Excel en français) :

- `medias/filRouge/commandes.csv` : les 2000 commandes de l'année 2025
 - `id_commande`, `date`
 - `canal` : d'où vient le client (SEO, SEA, Email, Réseaux sociaux, Direct)
 - `region`, `transporteur` (Colissimo, Chronopost, Mondial Relay)
 - `nb_articles`, `montant_eur` : le panier
 - `delai_livraison_jours`
 - `satisfaction` : note de 1 à 5 laissée par le client
 - `client_nouveau` : oui / non
- `medias/filRouge/visitesAB.csv` : 4000 visites du site pendant le test A/B de la page d'accueil (`version_page`, `appareil`, `achat`)
- `medias/filRouge/caHebdo.csv` : pour chacune des 52 semaines, le budget publicitaire et le chiffre d'affaires

3.2 Étape 1 : décrire (Excel)

Objectifs : 1) résumer un jeu de données par des chiffres et des graphiques 2) choisir le bon indicateur de position selon la forme de la distribution

Concepts : 1) moyenne, médiane, mode, quantiles 2) écart-type, écart inter-quartiles 3) effectifs, fréquences, effectifs cumulés 4) histogramme, boxplot, diagramme en bâtons

La direction veut *un* chiffre pour le panier moyen, à mettre dans la présentation aux actionnaires.

Étapes :

1. ouvrez `medias/filRouge/commandes.csv`
2. calculez pour `montant_eur` : moyenne, médiane, mode (arrondi à 10 €), écart-type, quantiles, minimum, maximum

- découpez le montant en classes ($[0, 25[$, $[25, 50[$, $[50, 75[$, $[75, 100[$, $[100, 150[$, $[150, 200[$, $[200, 300[$) et calculez effectifs, fréquences et fréquences cumulées croissantes (fonction **FREQUENCE**)
- tracez l'histogramme
- calculez les effectifs et fréquences par **canal** et par **transporteur** (tableau croisé dynamique ou **NB.SI**)
- calculez le délai de livraison moyen, médian et l'écart-type *par transporteur*
- tracez un boxplot du montant par canal (Excel : Insertion, graphique statistique, zone et valeur)

Questions :

- la moyenne et la médiane du panier sont différentes : pourquoi ? Laquelle donner à la direction ?
- quelle part du chiffre d'affaires est faite par les 10% de commandes les plus grosses ?
- que peut-on déjà dire, *sans aucun test*, sur les délais des trois transporteurs ?
- la satisfaction moyenne est de 3,5 sur 5. Est-ce un bon résumé de cette variable ?

3.3 Étape 2 : échantillonner (Excel, en groupe)

Objectifs : 1) ressentir la variabilité due à l'échantillonnage 2) faire le lien entre statistique descriptive et statistique inférentielle

Concepts : 1) population, échantillon 2) distribution d'échantillonnage de la moyenne 3) erreur standard, intervalle de confiance

Cette étape se fait *tous ensemble*. Le service client veut connaître le panier moyen et la satisfaction moyenne, mais il n'a le temps de rappeler que 30 clients.

Ici, nous avons la chance de connaître la population entière (les 2000 commandes). En pratique, on ne l'a jamais : on a *un* échantillon, et il faut en tirer une conclusion sur la population.

Étapes :

- chaque stagiaire tire au hasard 30 commandes : ajoutez une colonne **=ALEA()**, copiez-collez ses valeurs, triez, gardez les 30 premières lignes
- calculez la moyenne du panier et la satisfaction moyenne de *vos* 30 commandes
- le formateur note au tableau la moyenne du panier de chaque stagiaire
- calculez la moyenne et l'écart-type des valeurs du tableau
- calculez l'intervalle de confiance à 95% de *votre* moyenne : $\bar{x} \pm t_{0.975}^{29} \frac{s}{\sqrt{30}}$ (Excel : **LOI.STUDENT.INVERSE.BILATERALE(0,05;29) = 2,045**)
- comptez au tableau combien d'intervalles contiennent le vrai panier moyen (49,12 €)

Questions :

- les moyennes du tableau sont-elles toutes égales ? Toutes égales au vrai panier moyen ?
- comparez l'écart-type des moyennes du tableau à $\frac{31,01}{\sqrt{30}}$. Que constatez-vous ?
- la distribution du panier (étape 1) était très asymétrique. Et celle des moyennes du tableau ?
- quelle proportion d'intervalles de confiance contiennent le vrai panier moyen ? Est-ce cohérent avec « 95% » ?
- combien de clients faudrait-il rappeler pour connaître le panier moyen à ± 5 € près (à 95%) ? À ± 2 € ?

Animation : <presentation/animations/echantillonnage.html> rejoue cette expérience des milliers de fois avec la population des 2000 paniers.

3.4 Étape 3 : modéliser et prévoir (Excel)

Objectifs : 1) ajuster un modèle linéaire simple 2) lire ses paramètres et sa qualité 3) produire une prévision avec sa marge d'erreur

Concepts : 1) variable expliquée, variable explicative 2) régression linéaire, moindres carrés 3) coefficient de détermination R^2 , résidus 4) intervalle de confiance et intervalle de prédiction

La direction hésite à passer le budget publicitaire hebdomadaire de 3 000 € à 6 000 €. Elle veut savoir ce que cela rapporterait.

Étapes :

1. ouvrez `medias/filRouge/caHebdo.csv`
2. tracez le nuage de points chiffre d'affaires en fonction du budget publicitaire
3. ajoutez une courbe de tendance linéaire, affichez l'équation et le R^2
4. retrouvez la pente et l'ordonnée à l'origine avec `PENTE` et `ORDONNEE.ORIGINE`, le R^2 avec `COEFFICIENT.DETERMINATION`
5. calculez pour chaque semaine la valeur prédite par le modèle et le résidu (observé – prédit)
6. tracez les résidus en fonction du budget
7. calculez la prévision pour 6 000 € avec `PREVISION.LINEAIRE`
8. calculez l'intervalle de prédiction à 95% pour cette semaine-là : $\hat{y} \pm t_{0.975}^{n-2} s_{res} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x_i - \bar{x})^2}}$, avec s_{res} l'écart-type des résidus (`ERREUR.TYPE.XY`)

Questions :

1. que signifie concrètement la pente ? L'ordonnée à l'origine ?
2. le R^2 vaut 0,89 : que veut dire ce chiffre ?
3. les résidus ont-ils une structure (courbure, éventail) ? Qu'est-ce que cela changerait ?
4. quel chiffre d'affaires annoncer pour 6 000 € ? Avec quelle fourchette ?
5. la direction demande aussi une prévision pour 12 000 €. Que répondez-vous ?
6. quelle est la différence entre « le CA moyen des semaines à 6 000 € » et « le CA de la semaine prochaine à 6 000 € » ?

3.5 Étape 4 : tester (R)

Objectifs : 1) formuler H_0 et H_1 à partir d'une question métier 2) choisir le test adapté et interpréter sa p -value et son intervalle de confiance

Concepts : 1) test du χ^2 d'indépendance, comparaison de proportions 2) test de Student, ANOVA, test de Tukey 3) risque α , puissance, taille d'effet

Pour chaque question, écrivez d'abord H_0 , H_1 et le test choisi, *avant* de lancer le calcul.

3.5.1 Le test A/B

Pendant un mois, la moitié des visiteurs a vu l'ancienne page d'accueil (A), l'autre moitié la nouvelle (B).

Étapes :

1. chargez `medias/filRouge/visitesAB.csv` (`read.table(..., sep=";", dec=".", header=TRUE)`)
2. construisez le tableau croisé version × achat (`table`)
3. calculez le taux de conversion de chaque version
4. testez avec `chisq.test` ou `prop.test`

Questions :

1. la version B convertit-elle mieux ? Que répondez-vous à la direction, qui veut déployer B dès demain ?
2. combien de visites par version aurait-il fallu pour détecter de façon fiable un passage de 3% à 4% ?

3.5.2 Chronopost vaut-il son prix ?

Étapes :

1. chargez `medias/filRouge/commandes.csv`
2. comparez le délai de livraison Colissimo / Chronopost avec `t.test`
3. construisez le tableau transporteur $\times$ satisfait (note ≥ 4) et testez l'indépendance avec `chisq.test`

Questions :

1. de combien de jours Chronopost est-il plus rapide, avec quelle précision ?
2. la satisfaction dépend-elle du transporteur ? Dans quel sens ?

3.5.3 Les clients emailing dépensent-ils plus ?

Étapes :

1. testez l'effet du canal sur le montant avec `aov` puis `anova`
2. identifiez les canaux qui diffèrent avec `TukeyHSD`

Questions :

1. le canal a-t-il un effet sur le panier ? Lequel se distingue ?
2. le panier moyen global est de 49,12 €. L'objectif de la direction était 50 €. Est-il atteint ?

3.6 Étape 5 : vérifier l'adéquation à un modèle (Excel ou R)

Objectifs : 1) confronter une loi théorique aux données 2) savoir quand une hypothèse de normalité compte, et quand elle ne compte pas

Concepts : 1) loi normale, loi log-normale 2) χ^2 d'adéquation, effectifs observés et attendus 3) théorème central limite, résidus

Un collègue a écrit dans un rapport : « le panier suit une loi normale de moyenne 49 € et d'écart-type 31 €, donc 95% des paniers sont entre $49 - 2 \times 31 = -13$ € et 111 € ».

Étapes :

1. reprenez les classes de montant de l'étape 1 et leurs effectifs observés
2. calculez, pour chaque classe, l'effectif attendu si le montant suivait $\mathcal{N}(49,12; 31,01^2)$ (Excel : `LOI.NORMALE.N(borne;49,12;31,01;VRAI)`, différence entre les deux bornes, $\times 2000$)
3. recommencez avec une loi log-normale : $\log(\text{montant})$ de moyenne 3,732 et d'écart-type 0,563 (calculez-les : `MOYENNE` et `ECARTYPE.STANDARD` de la colonne `LN(montant)`) (`LOI.LOGNORMALE.N`)
4. comparez observé et attendu (graphiquement, puis avec `CHISQ.TEST` ou `chisq.test`)
5. pour la régression de l'étape 3 : tracez l'histogramme des résidus et le nuage résidus / valeurs prédites

Questions :

1. que penser de la phrase du collègue ?
2. laquelle des deux lois décrit le mieux le panier ? Comment le dire à quelqu'un qui ne connaît pas le χ^2 ?
3. le montant n'est pas normal. Est-ce un problème pour l'intervalle de confiance du panier moyen (étape 2) ? Pour l'ANOVA (étape 4) ? Pour prévoir le montant d'une commande ?
4. les résidus de la régression sont-ils compatibles avec une loi normale ? Pourquoi est-ce cette hypothèse-là qui compte pour l'intervalle de prédiction ?

3.7 Étape 6 : le rapport à la direction

Objectifs : 1) concevoir un rapport d'analyse basé sur les faits 2) formuler une conclusion statistique en français, sans jargon et sans surinterprétation

Rédigez, en une page maximum, la réponse aux cinq questions de la direction (voir le contexte). Contraintes :

Étapes :

1. une phrase de réponse par question, compréhensible par quelqu'un qui n'a pas suivi ce cours
2. chaque chiffre est accompagné de sa précision (intervalle de confiance) ou de son effectif
3. on distingue ce qui est *démontré*, *probable*, et *inconnu*
4. on termine par une recommandation et, si besoin, par ce qu'il faudrait mesurer en plus

Questions :

1. relisez votre texte : où avez-vous écrit « prouve », « significatif », « la probabilité que » ? Est-ce justifié ?

4 Pour aller plus loin

4.1 Calcul d'effectifs cumulés croissants

Objectifs : 1) séparer des données en classes 2) calculer les effectifs d'une classe 3) utiliser une représentation graphique pour tirer des indicateurs 4) manipuler des opérations matricielles dans Excel

Concepts : 1) statistiques de base 2) représentation graphique

Le fichier `medias/descriptives/salaires/entrepriseA.csv` contient les salaires des employés de l'entreprise A. On souhaite mieux connaître la répartition des salaires dans l'entreprise.

Étapes :

1. définissez des classes de salaires (de 1100€ à 20000€) par pas de 500 € (classes : [1000, 1500[, [1500, 2000[, ...)
2. trouvez le nombre de salariés dans chaque classe (effectif)
3. calculez les effectifs cumulés croissants

Questions :

1. quelles représentations graphiques peut-on effectuer ?
2. puis-je me servir de cette méthode pour la comparer à une autre entreprise ? (par exemple celle dont les salaires sont dans `medias/descriptives/salaires/entrepriseB.csv`)
3. que peut-on penser de la classe de salaires pour laquelle la fréquence cumulée croissante est 0.5 ?

4.2 Étude de cas

Objectifs : 1) exploration d'un jeu de données 2) tirer des conclusions à partir de l'exploration

Concepts : 1) manipulation de données 2) méthodes numériques de statistique descriptive univariée (moyenne, médiane, variance) 3) statistiques descriptives multivariées 4) *dataviz*

Le jeu de données bébé contient un échantillon de nouveau-nés caractérisés par les variables suivantes :

1. `bwt` : le poids du bébé à la naissance
2. `weight` : le poids de la mère au début de la grossesse (en kg)
3. `height` : la taille de la mère en début de grossesse (en cm)
4. `age` : l'âge de la mère (en années)
5. `gestation` : la durée de la grossesse (en jours)

6. **parity** : terme gynécologique (vrai si premier accouchement donnant un enfant vivant, false sinon)
7. **smoke** : indique le tabagisme de la mère (vrai si elle fume, false sinon)

Dans un premier temps, nous allons chercher à explorer les données séparément.

Étapes :

1. ouvrez le fichier présent dans le dossier `medias/descriptives/etudeDeCas.csv`
2. calculez l'indice de masse corporelle (IMC) pour la mère (rappel : $IMC = \frac{Masse}{Taille^2}$, unités : masse en kg, taille en mètres)
3. calculez les paramètres de position et de dispersion pour les variables quantitatives
4. calculez les effectifs pour les variables qualitatives
5. effectuez les représentations graphiques

Questions :

1. pouvons-nous voir des individus atypiques ?

Nous cherchons maintenant à savoir parmi les variables, celles qui pourraient expliquer la variation du poids du bébé.

Étapes :

1. visualisations des variables qualitatives (poids en fonction de IMC, taille, poids de la mère, temps de gestation, ...)
2. discrimination par les variables binaires (quelle visualisation utiliser ?)
3. visualisation quali-quali-quant (taille du bébé, selon l'IMC de la mère en fonction de si elle fume ou non). Utilisez différentes séries dans les graphiques Excel pour cela.

Questions :

1. dans ce cas, quelles sont les variables explicatives et expliquées ?
2. comment visualiser l'impact du temps de gestation sur la masse des bébés ?
3. la masse des bébés est-elle influencée par le temps de gestation ?

4.3 Génération de données aléatoires

Objectifs : 1) créer un fichier CSV 2) expérimenter la génération de données aléatoires

Concepts : 1) lois statistiques

Les fichiers de salaires ont été générés.

Comment peut-on le recréer ?

Étapes :

1. trouver les fonctions de génération de nombres aléatoires
2. créer une colonne avec 200 salaires
3. sauvegarder le fichier comme CSV

Questions :

1. quels sont les impacts des options choisies pour l'enregistrement
2. quel est l'impact du choix de la loi statistique

4.4 Estimation et intervalles : les ampoules

Objectifs : 1) savoir estimer différents paramètres à partir d'un échantillon 2) savoir calculer les intervalles de confiance de ces paramètres

4.4.1 Moyenne

En tant que constructeur d'ampoules, nous nous devons de connaître la durée de vie de nos produits. Nous avons mesuré la durée de vie de 50 ampoules.

Étapes :

1. chargez le fichier `medias/testsHypotheses/ampoules.csv`

Questions :

1. calculez l'intervalle de confiance de la moyenne à 1%, 5% et 10%

4.4.2 Différence de moyennes

Nous voulons savoir si nos ampoules sont meilleures que celles de notre concurrent direct. Nous avons acheté 50 de ses ampoules.

Étapes :

1. chargez le fichier `medias/testsHypotheses/ampoulesConcurrent.csv`
2. calculez la moyenne et l'écart-type de chacun des deux échantillons (le nôtre, celui du concurrent)

Questions :

1. calculez l'intervalle de confiance de la différence de moyennes à 1%, 5% et 10%

4.4.3 Fréquence

Sur les 50 ampoules que nous avons testées, 3 étaient défectueuses.

Questions :

1. donnez la fréquence des défauts sur la population totale avec un risque de 5% ?

4.5 Estimation de tailles d'échantillon

Concepts : 1) estimation de la taille d'un échantillon 2) prise de risque, z-score 3) inférence statistique

Nous cherchons à estimer la taille d'un échantillon pour une étude politique. Nous souhaitons connaître les intentions de vote pour un candidat.

La population est de 70 millions d'habitants, le risque que nous sommes prêts à prendre est de 1% et la marge d'erreur, de 2%, on ne connaît pas les intentions de vote pour le candidat.

Questions :

1. combien de personnes questionner ?
2. si l'on ne connaissait pas la taille de la population, quel aurait été l'impact ?
3. si l'on savait que les intentions de vote étaient de 30% pour le candidat, quel impact sur l'échantillon ?
4. comparer avec des tailles d'échantillons de sondages politiques pour les élections présidentielles

4.6 Test de Student (ou *t-test*)

Objectifs : 1) comprendre la notion d'hypothèse nulle 2) maîtriser l'utilisation du test de Student

J'ai deux chaînes de production de cure-dents dans l'usine 1 et je souhaiterais savoir si les produits qui en sortent sont du même calibre (s'ils ont en moyenne la même taille). La taille de cure-dent idéale est de 53mm d'après le service marketing.

Étapes :

1. chargez les données `medias/testsHypotheses/testStudent1.csv`
2. effectuez un test de Student sur ces données

Je souhaiterais également vérifier dans l'usine 2

Étapes :

1. chargez les données du fichier `medias/testsHypotheses/testStudent2.csv`
2. effectuez un test de Student sur ces données

Questions :

1. qu'en concluez-vous pour l'usine 1 ?
2. qu'en concluez-vous pour l'usine 2 ?
3. y a-t-il une différence en moyenne sur la longueur des cure-dents produits ?

4.7 χ^2

Concepts : 1) notion d'hypothèse nulle 2) inférence statistique 3) χ^2 d'appartenance

En vacances à Monte-Carlo, je souhaite jouer aux dés au Casino.
J'ai réussi à me souvenir de l'apparition des faces et à la noter.

Étapes :

1. chargez les données du fichier `medias/testsHypotheses/desComptage.csv`
2. effectuez un test du χ^2 sur ces données

Questions :

1. allez-vous miser vos économies avec ce dé ?

4.8 ANOVA

Objectifs : 1) comprendre la notion d'hypothèse nulle 2) maîtriser l'utilisation de l'ANOVA

On souhaite connaître l'effet de la dose d'un médicament dans la baisse de fièvre dans le cadre de syndrome grippal.
Nous avons mesuré dans 3 échantillons de malades différents la température (en °C).

- le groupe témoin : sans traitement
- le groupe soumis au traitement à 500mg
- le groupe soumis au traitement à 1000mg

Étapes :

1. chargez les données de l'étude `medias/testsHypotheses/anovaMedicament.csv`
2. effectuez une ANOVA sur les données

Questions :

1. la dose a-t-elle une influence sur la baisse de la fièvre ?
2. quelle dose est la plus efficace ?

4.9 Étude de cas

Objectifs : 1) apprendre à manipuler R

Concepts : 1) opérations vectorielles 2) variables / dataframes 3) statistiques descriptives

Refaites l'étude de cas sur les bébés en R.