

Formation Modélisation statistique, l'essentiel

Matthieu Falce

8 et 9 octobre 2026

Au programme I

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Au programme II

Références

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

À propos de moi

Matthieu Falce

- ▶ Matthieu Falce, Lille
- ▶ ingénieur en bioinformatique (INSA Lyon)
- ▶ parcours
 - ▶ ingénieur R&D en interaction homme-machine à l'Inria Lille (équipes [Mint](#) puis [Mjolnir](#)) : expériences utilisateurs, plans d'expérience, analyse des résultats
 - ▶ développeur *fullstack* / *backend* à [FUN-MOOC](#) (France Université Numérique)
- ▶ aujourd'hui, indépendant
 - ▶ formateur : [Oh Ce Cours Formation](#)
 - ▶ missions de développement et de conseil pour des startups, des scaleups et des grands comptes
 - ▶ Ekla, studio de développement logiciel
 - ▶ CTO d'[ETYC](#) (plateforme de suivi environnemental pour les yachts), ancien CTO d'ExcellencePriority
 - ▶ coorganisateur de meetups à Lille ([Python](#), [big data et machine learning](#))

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Ce que vous pouvez attendre de moi

Matthieu Falce

- ▶ **Pragmatisme** : je suis un praticien, pas un universitaire. On part de vos questions et de vos données, et on s'attarde sur ce que vous pourrez réutiliser dans votre travail.
- ▶ **Pédagogie** : l'intuition avant la formule, la pratique toutes les vingt minutes. Il n'y a pas de question bête, surtout pas celles qu'on n'ose pas poser.
- ▶ **Compétence** : des années de terrain en développement, en données et en formation.

À vous : qui êtes-vous, et qu'attendez-vous de ces deux jours ?

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Où me trouver ?

- ▶ mail : matthieu@falce.net
- ▶ GitHub : [ice3](https://github.com/ice3)
- ▶ site : falce.net
- ▶ LinkedIn : [matthieu-falce](https://www.linkedin.com/company/matthieu-falce)

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Définition

Types de variables

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

1- Concepts en statistique

1.1. Définition

À l'origine, surtout étude méthodique des faits sociaux qui définissent un État.

- ▶ du latin *status* (en lien avec l'état)
- ▶ de tous temps, besoin des puissants de connaître ce qu'ils possèdent

Moyens :

- ▶ inventaires
- ▶ dénombremments
- ▶ recensements
- ▶ ...

Concepts en statistique

Définition

Types de variables

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Problème :

- ▶ complexité croissante des données
- ▶ quantité de données à prendre en compte

Formalisation du domaine nécessaire.

Des *statistiques* à la *Statistique*

Matthieu Falce

Concepts en
statistique

Définition

Types de variables

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Vers 1830 $\Rightarrow$ formalisation d'un ensemble de techniques d'interprétation mathématiques appliquées à des phénomènes

- ▶ la Statistique
 - ▶ étude d'un phénomène (collecte de données, traitement, analyse, interprétation, présentation des résultats)
 - ▶ science, méthode et ensemble de techniques
- ▶ les statistiques : le produit de la Statistique

La Statistique publique (l'INSEE), et les statistiques publiques (le nombre d'habitants en France)

Statistique Descriptive

- ▶ décrire des données de façon synthétique et parlante
- ▶ pour mieux les analyser et les comprendre
- ▶ effectuer un *résumé* quand trop de données à interpréter

Moyens :

- ▶ valeurs calculées (moyenne, ...)
- ▶ représentations graphiques

Exemple :

- ▶ analyse des distributions des salaires dans une entreprise

Concepts en
statistique

Définition

Types de variables

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Types de statistiques

Matthieu Falce

Statistique inférentielle : estimation et prévisions à partir d'un sous-ensemble de la population

Moyens :

- ▶ outils mathématiques
- ▶ théorie
- ▶ estimation du risque de se tromper

Exemples :

- ▶ analyse efficacité d'un médicament
- ▶ sondages

Concepts en statistique

Définition

Types de variables

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

De la population à l'individu

Matthieu Falce

- ▶ individu
 - ▶ élément individuel sur lequel est considérée l'analyse statistique
 - ▶ l'analyse peut être destructrice ou non
 - ▶ exemple : un boulon, une personne, ...
- ▶ population
 - ▶ l'ensemble des individus que l'on veut connaître
 - ▶ impossible à connaître exhaustivement (coût en temps, argent)
 - ▶ exemple : les salariés d'une entreprise, les boulons fabriqués par une usine...
- ▶ échantillon
 - ▶ partie de la population soumise à l'analyse statistique
 - ▶ exemple : personnes sondées (pour un sondage), boulons choisis pour QA...

Concepts en statistique

Définition

Types de variables

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

De la population à l'individu

Matthieu Falce

Concepts en
statistique

Définition

Types de variables

Démarche
statistique

Statistique
Descriptive


Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références



● Individu

● Echantillonnage

De la population à l'individu

Matthieu Falce

Concepts en
statistique

Définition

Types de variables

Démarche
statistique

Statistique
Descriptive


Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références



● Individu

● Echantillonnage

1- Concepts en statistique

1.2. Types de variables

Mesurent une quantité

- ▶ continue : est-ce que je peux placer un élément entre deux valeurs ? (âge, taille, poids)
- ▶ discrète : nombre limité de possibilités (nombre de personnes dans une pièce)

Mesurent une qualité (description)

- ▶ binaires : 2 valeurs (sexe : Homme / Femme)
- ▶ nominales : ne peuvent pas être ordonnées (nom des couleurs)
- ▶ ordinales : peuvent être ordonnées (appréciation, classement)

On peut grouper les données dans des classes.

Une classe est définie par son *intervalle* : $[a, b[$ (a inclus, b exclus)



Ne pas mettre d'intervalles ouverts aux extrêmes (par exemple $> 20 \text{ ans}$), car ils empêchent certains calculs

Exemple :

Taille des élèves (en cm)

164 156 186 170 183 183 163 152 180 151

Taille des élèves (en cm)

	100 - 119	120 - 139	140 - 159	160 - 179	180 - 199
effectifs	0	0	3	3	4
fréquences	0	0	0.3	0.3	0.4

Nombre d'éléments dans chaque classe : *effectif*

Nombre d'éléments dans chaque classe divisé par le nombre d'éléments total : *fréquence*

Concepts en
statistique

**Démarche
statistique**

Étapes de la démarche
statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Démarche statistique

Concepts en
statistique

Démarche
statistique

**Étapes de la démarche
statistique**

Hypothèse et risque

Collecte des données

Description des données

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

2- Démarche statistique

2.1. Étapes de la démarche statistique

Étapes à suivre

Matthieu Falce

l'étape		par exemple : une nouvelle page d'accueil
1	poser la question, et la décision qui en dépend	« fait-elle acheter plus ? » si oui, on la déploie pour tout le monde
2	fixer le risque qu'on accepte, et le plus petit effet qui compte	5 % de risque de déployer une page qui ne change rien ; moins d'un point de conversion ne vaut pas le coup
3	définir le protocole : quoi mesurer, sur qui, combien, tirés comment	chaque visiteur voit A ou B au hasard, on note s'il achète ; 5 000 visites par version, calculées depuis l'étape 2
4	décrire et nettoyer les données	3,1 % d'achats sur A, 4,2 % sur B, robots et visites internes retirés
5	modéliser, tester, vérifier que le modèle tient	si A et B convertissaient pareil, 1,1 point d'écart serait-il surprenant ? le test est-il valable avec ces données ?
6	conclure avec l'incertitude, et rendre compte	« B convertit environ 1 point de mieux (entre 0,4 et 1,8) : on déploie B », pas « B est meilleure »

Dans le fil rouge, ce test a été lancé avec 2 000 visites par version, sans l'étape 2. Vous verrez ce que ça donne.

Concepts en statistique

Démarche statistique

Étapes de la démarche statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

L'étape de définition du protocole est extrêmement importante.

- ▶ que dois-je mesurer ?
- ▶ comment ?
- ▶ combien d'éléments par catégories ? / répétitions ?
- ▶ ...



Notion de *plan d'expérience*

Idéalement le statisticien intervient déjà à ce moment-là.

Concepts en
statistique

Démarche
statistique

Étapes de la démarche
statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Le statisticien, avant ou après ?

Matthieu Falce

Faire appel au statisticien une fois l'expérience terminée, c'est souvent lui demander une autopsie : il pourra peut-être vous dire de quoi l'expérience est morte.

Ronald Fisher, 1938

« To call in the statistician after the experiment is done may be no more than asking him to perform a post-mortem examination : he may be able to say what the experiment died of. »

R. A. Fisher, Presidential Address, *Sankhyā : The Indian Journal of Statistics*, vol. 4, n° 1 (1938), p. 17

Aucune analyse, aussi savante soit-elle, ne rattrape des données mal collectées.

Concepts en statistique

Démarche statistique

Étapes de la démarche statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Sélectionner sur la réponse

- ▶ je n'ai récupéré que des données de personnes vaccinées : forcément, « tout le monde est vacciné »
- ▶ on ne contrôle que les entreprises signalées : le taux d'irrégularité observé ne dit rien de l'ensemble
- ▶ on n'analyse que les pièces rejetées, que les clients qui ont répondu à l'enquête

Ne voir que les survivants

- ▶ 1943, Abraham Wald : on voulait blinder les avions là où les avions revenus étaient criblés d'impacts. Il fallait blinder ailleurs : les avions touchés là ne revenaient pas.
- ▶ un indice de prix calculé sur les seuls produits encore référencés, une étude sur les seules entreprises encore en activité

Concepts en statistique

Démarche statistique

Étapes de la démarche statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Ne pas avoir de point de comparaison

- ▶ « depuis la nouvelle procédure, les incidents ont baissé » : ils baissaient peut-être déjà, ou c'est la saison
- ▶ sans groupe témoin, on ne sépare pas l'effet de ce qui serait arrivé de toute façon

Ne pas tirer au hasard

- ▶ ce sont les meilleurs opérateurs qui testent la nouvelle machine, les volontaires qui essaient le nouveau process
- ▶ l'effet mesuré mélange la machine et l'opérateur

Ne pas noter la variable qui gêne

- ▶ site, équipe de nuit, lot de matière première, opérateur, âge : si elle n'a pas été relevée, aucune analyse ne pourra la corriger

Concepts en statistique

Démarche statistique

Étapes de la démarche statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Changer la mesure en cours de route

- ▶ nouveau capteur, nouvel instrument, nouvelle définition d'un indicateur : la « tendance » vient de la mesure

Données manquantes qui ne manquent pas au hasard

- ▶ les clients mécontents ne répondent pas, les essais ratés ne sont pas saisis

Échantillon trop petit pour l'effet cherché

- ▶ 20 mesures pour détecter un écart de 1 % : la conclusion « pas d'effet » est écrite d'avance

Choisir la question après avoir vu les données

- ▶ on teste 20 sous-groupes, l'un d'eux sort « significatif » à 5 % : c'est attendu, pas une découverte

Concepts en statistique

Démarche statistique

Étapes de la démarche statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Avant de collecter : les questions à se poser

Matthieu Falce

1. quelle question précise ? quelle décision prendrai-je selon la réponse ?
2. quelle population veut-on connaître ? est-ce bien celle qu'on va atteindre ?
3. comment choisit-on les individus ? (au hasard, par strates, ...)
4. à quoi compare-t-on ? (groupe témoin, situation avant)
5. quelles variables relever, y compris celles qui pourraient tout expliquer à notre place ?
6. combien d'individus pour voir l'effet qui nous intéresse ?
7. qui mesure, avec quel instrument, toujours de la même façon ?
8. que fera-t-on des données manquantes ?

Dix minutes avec ces questions évitent des semaines d'autopsie.

Concepts en statistique

Démarche statistique

Étapes de la démarche statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Démarche
statistique

Étapes de la démarche
statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

2- Démarche statistique

2.2. Hypothèse et risque

Concepts en
statistique

Démarche
statistique

Étapes de la démarche
statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

La question qui nous pousse à faire tous ces efforts

- ▶ le médicament a-t-il un effet ?
- ▶ ce dé est-il pipé pour faire mes paris ?
- ▶ qui sera le prochain président de la République ?
- ▶ ces machines-outils fabriquent-elles des objets équivalents ?

Décider c'est prendre un risque

Les valeurs choisies dans l'échantillon dépendent du hasard.

Quel risque sommes-nous prêts à prendre :

- ▶ que nous décidions qu'il y ait quelque chose de remarquable
- ▶ alors que cela n'est dû qu'au hasard de l'échantillonnage

Les valeurs classiques de risques :

- ▶ 1% / 0.01
- ▶ 5% / 0.05 (grand classique, si vous ne savez pas, prenez cette valeur)
- ▶ 10% / 0.1

Concepts en statistique

Démarche statistique

Étapes de la démarche statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Démarche
statistique

Étapes de la démarche
statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

2- Démarche statistique

2.3. Collecte des données

Échantillonnage

Matthieu Falce

Il est *impossible* d'étudier une population entière.

Sous-ensemble (*sample*) de la population en échantillonnant
(*sampling*)



Taille de l'échantillon : au cas par cas (plus d'individus et mieux c'est).

Il s'agit d'un compromis coût / certitude.

Concepts en
statistique

Démarche
statistique

Étapes de la démarche
statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

- ▶ échantillon empirique
 - ▶ méthode des quotas (on cherche à avoir une version miniature de la population totale)
 - ▶ échantillon de convenance (ce qui arrange le chercheur en termes de praticité ou de coût)
 - ▶ *stop and go* (on échantillonne jusqu'à avoir suffisamment d'individus d'intérêt, adaptation de la taille d'échantillon jusqu'à la conclusion, utilisé en audit pour la détection de fraude par exemple)
- ▶ échantillon aléatoire
 - ▶ tirage au sort (on détermine aléatoirement les individus à étudier)
 - ▶ échantillon stratifié (on tire au hasard mais en définissant des groupes)

Concepts en
statistique

Démarche
statistique

Étapes de la démarche
statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Indépendance des mesures

Matthieu Falce

L'indépendance est difficile à avoir en pratique.

- ▶ même opérateur de mesure
- ▶ même source de données
- ▶ ...

Cela peut être négligé dans certains cas.

Cas non indépendants :

- ▶ mesures répétées sur un même individu (on parle de mesures appariées)
 - ▶ fièvre d'un patient avant et après la prise d'un médicament
 - ▶ mesurage d'un élément au cours des étapes de fabrication

Concepts en statistique

Démarche statistique

Étapes de la démarche statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Démarche
statistique

Étapes de la démarche
statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

2- Démarche statistique

2.4. Description des données

Défrichage des données obtenues.

- ▶ résumé visuel
- ▶ résumé numérique

Réponse aux questions suivantes :

- ▶ des informations semblent-elles redondantes ?
- ▶ les données peuvent-elles répondre aux questions posées ?

Certaines variables peuvent varier avec d'autres

Exemple :

- ▶ âge et ancienneté sur un poste
- ▶ taux de divorce dans le Maine (état américain) et la consommation de margarine par Américain
- ▶ ...¹




Corrélation $\neq$ causalité Il faut réfléchir à l'origine du lien

¹ Il y a même un livre entier sur des corrélations étranges : Spurious Correlations de Tyler Vigen
barnesandnoble.com

Variables corrélées

Matthieu Falce

Certaines variables peuvent varier avec d'autres



tylervigen.com

Concepts en statistique

Démarche statistique

Étapes de la démarche statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Cas des individus exceptionnels (*outliers*)

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Étapes de la démarche
statistique

Hypothèse et risque

Collecte des données

Description des données

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Dans certains cas, l'analyse descriptive montrera des individus exceptionnels.

- ▶ ils peuvent avoir un impact sur les analyses
- ▶ les garder, les supprimer ou les modifier ?
 - ▶ à décider au cas par cas
 - ▶ comprendre l'origine du problème

On peut appliquer des modifications pour que les données respectent plus d'hypothèses pour les tests

- ▶ centrage (moyenne à 0) / réduction (variance à 1)
- ▶ fonctions mathématiques (mise à une puissance ou racine, $\log$ / $\exp$)
- ▶ ...

Concepts en
statistique

Démarche
statistique

**Statistique
Descriptive**

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Statistique Descriptive

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

3- Statistique Descriptive

3.1. Critères de position

La tendance centrale désigne le point autour duquel se regroupent à un certain degré les différentes valeurs d'une variable quantitative mesurées dans un échantillon ou issues d'une population, c'est-à-dire le « centre » autour duquel ces valeurs "tendent" à se concentrer

Wikipédia : [Tendance centrale](#)

Les valeurs les plus connues :

- ▶ mode
- ▶ moyenne
- ▶ médiane

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Le mode désigne la valeur la plus fréquente de la distribution

- ▶ distribution mono-modale (un seul mode)
- ▶ distribution multimodale (plusieurs modes)

164 156 186 170 183 183 163 152 180 151

Mode : 183

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{i=n} x_i$$

La moyenne est l'indicateur le plus simple pour résumer l'information fournie par un ensemble de données statistiques : elle est égale à la somme de ces données divisée par leur nombre.

Moyenne arithmétique

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{i=n} x_i$$

Exemple (taille en cm des élèves d'une classe) :

164 156 186 170 183 183 163 152 180 151

Moyenne : 168.8 cm

Moyenne arithmétique

Matthieu Falce

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{i=n} x_i$$



La moyenne n'est pas forcément le meilleur indicateur $\Rightarrow$
sensibilité aux valeurs extrêmes.

164 156 186 170 183 183 163 152 180 **1051**

Moyenne : 258.8

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Moyenne arithmétique

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{i=n} x_i$$

Propriétés :

- ▶ stabilité par transformation affine si $y_i = ax_i + b$ alors $\bar{y} = a\bar{x} + b$
- ▶ si 2 populations P_1 et P_2 , de taille n_1 et n_2 ont comme moyenne $\bar{x}_1$ et $\bar{x}_2$ alors la moyenne $\bar{x}$ de la population totale P est $\bar{x} = \frac{n_1\bar{x}_1 + n_2\bar{x}_2}{n_1 + n_2}$ (barycentre des moyennes)

Effectifs cumulés croissants

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Somme des effectifs d'une classe avec la somme des classes précédentes.

Utilisés pour calculer des mesures statistiques

Exemple :

notes (ordonnées)	5	8	9	10	11	12	13	14	16
effectifs	1	1	1	3	4	5	1	2	3
effectifs cumulés croissants	1	2	3	6	10	15	16	18	21

Effectifs cumulés croissants

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données


Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références



La médiane sépare la population en deux populations égales.
Elle se base sur le rang des observations (il faut les ordonner)

Calcul :

- ▶ cas discret impair 4, 5, 6, 7, 8, 9, 10 médiane : 7
- ▶ cas discret pair 4, 5, 6, 7, 8, 9, médiane : 6.5 (moyenne de 6 et 7)
- ▶ cas continu : on utilise les effectifs cumulés croissants et on fait une interpolation linéaire entre les points qui entourent 50%

La médiane peut donc être une valeur qui n'existe pas dans les données

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

La médiane sépare la population en deux populations égales.
Elle se base sur le rang des observations (il faut les ordonner)

Meilleure résistance aux valeurs aberrantes :

164 156 186 170 183 183 163 152 180 151

Médiane : 167

164 156 **1086** 170 183 183 163 152 180 151

Médiane : 167

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Quantiles

Matthieu Falce

Les quantiles sont les valeurs qui divisent un jeu de données en sous-populations contenant le même nombre de données.



Il y a au maximum $N - 1$ quantiles sur une population de taille N .

Permettent de quantifier les valeurs extrêmes d'une série.
Calcul :

- ▶ on ordonne les données
- ▶ on calcule les effectifs / fréquences cumulés croissants
- ▶ on détermine les points qui correspondent aux fréquences seuils

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R


Références

Quelques quantiles connus :

- ▶ quartiles : 3 valeurs qui partagent en 4 sous-populations de même taille
- ▶ déciles : 9 valeurs qui partagent en 10 sous-populations de même taille (ex. en hydrologie le 9^e décile correspond à une crue décennale)
- ▶ centiles : 99 valeurs qui partagent en 100 sous-populations de même taille (ex. en hydrologie le 99^e centile correspond à une crue centennale)
- ▶ cas particulier de la médiane

Résumé graphique

Matthieu Falce



Source : ecom-store.fr

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

3- Statistique Descriptive

3.2. Critères de dispersion

La dispersion représente la variabilité ou l'étendue des différentes valeurs que peut prendre une variable.

Peut être représentée par :

- ▶ variance
- ▶ écart-type
- ▶ écart interquartile

S'oppose à la notion de tendance centrale.

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Différence entre la valeur maximale et minimale de la série.

$$\text{étendue} = x_{\max} - x_{\min}$$

Calcul :

164 156 186 170 183 183 163 152 180 151

Étendue : 35 (186 – 151)



L'étendue est plutôt sensible aux valeurs aberrantes.

Écart inter-quartiles

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Différence entre le troisième quartile et le premier quartile.

$$\text{Écart interquartile} = Q_3 - Q_1$$

Moins sensible aux *outliers* que l'étendue car élimine les valeurs extrêmes.

Écarts à la moyenne

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Série des écarts : $e_i = x_i - \bar{x}$

Comment étudier cette série ?

$$\sum_{i=1}^{i=n} e_i = 0$$

Il faut sommer des valeurs positives.

On ne peut pas utiliser la valeur absolue car la fonction n'est
pas *pratique*.

Utilisation de la fonction *carré*

Variance : moyenne des carrés des écarts à la moyenne.

$$V = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

La variance peut aussi se calculer plus facilement comme *la moyenne des carrés moins le carré de la moyenne*

$$V = \frac{1}{n} \sum_{i=1}^n (x_i)^2 - \bar{x}^2$$

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Variance : moyenne des carrés des écarts à la moyenne.

$$V = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$



La variance n'a pas la même unité que la variable de base, on ne peut pas interpréter sa valeur facilement.

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Écart-type (*standard deviation*)

Matthieu Falce



On ne peut pas additionner moyenne et variance. Comment faire ?

On utilise l'écart-type

$$\sigma = \sqrt{V} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i)^2 - \bar{x}^2}$$

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire


Tests d'hypothèses

R

Références

Écart-type (*standard deviation*)

Matthieu Falce



Source : Wikipédia : Statistical dispersion

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Variance : diviser par n ou par $n - 1$?

Il existe deux formules, et les logiciels proposent les deux.

On a mesuré *toute* la population

$$\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Excel : VAR.P,
ECARTYPE.PEARSON

R : pas de fonction directe

On a un *échantillon*

$$\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Excel : VAR.S,
ECARTYPE.STANDARD
R : var(), sd()

- ▶ diviser par $n - 1$ corrige le fait qu'un échantillon sous-estime la dispersion de la population
- ▶ en pratique on travaille presque toujours sur un échantillon : VAR.S, var()
- ▶ pour n grand, la différence est négligeable

Moments d'ordres supérieurs

Pour aller plus loin

Les moments sont des indicateurs de la dispersion d'une variable.

- ▶ moment d'ordre 1 : *espérance* (moyenne)
- ▶ moment (centré) d'ordre 2 : *variance*
- ▶ moment (centré réduit) d'ordre 3 : *skewness* (*coefficient d'asymétrie*)
- ▶ moment (centré réduit) d'ordre 4 : *kurtosis* (coefficient d'aplatissement)

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire


Tests d'hypothèses

R

Références

Moments d'ordres supérieurs

Pour aller plus loin



Source : [Wikipédia : Asymétrie \(statistiques\)](#)

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire


Tests d'hypothèses

R

Références

Moments d'ordres supérieurs

Pour aller plus loin



Source : <https://en.wikipedia.org/wiki/Kurtosis>

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Covariance

On utilise la covariance pour déterminer si deux variables aléatoires sont corrélées.

Calcul (E représente l'espérance mathématique) :

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))]$$

Propriétés :

- ▶ la covariance peut être négative, nulle ou positive
- ▶ si les variables sont indépendantes alors la covariance est nulle (la réciproque n'est pas vraie en général)
- ▶ coefficient de corrélation : $r = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$
- ▶ r varie entre -1 et 1 : si positif, l'augmentation d'une valeur entraîne celle de l'autre, et réciproquement
- ▶ si $r = -1$ ou $r = 1$: une variable explique parfaitement l'autre

Covariance

Pour aller plus loin

Matrice de variance-covariance : chaque élément est la covariance entre la variable de la colonne et celle de la ligne.

Les diagonales sont les variances.

Si les données sont centrées-réduites on parle aussi de matrice de corrélation.

$$\begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \ddots & \cdots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, X_1) & \cdots & \cdots & \text{Var}(X_p) \end{pmatrix}$$

=

$$\begin{pmatrix} \sigma_{x_1}^2 & \sigma_{x_1 x_2} & \cdots & \sigma_{x_1 x_p} \\ \sigma_{x_2 x_1} & \ddots & \cdots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{x_p x_1} & \cdots & \cdots & \sigma_{x_p}^2 \end{pmatrix}$$

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire


Tests d'hypothèses

R

Références

Covariance

Matthieu Falce



Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Source : Wikipédia : Corrélation (statistiques)

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

3- Statistique Descriptive

3.3. Visualisation de données

Objectif et méthode

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Objectif :

- ▶ vision globale du jeu de données
- ▶ trouver les liens entre des variables

Méthode :

- ▶ travailler variable par variable
- ▶ rajouter les liens entre les variables au fur et à mesure

Variables quantitatives uniques

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle


Modélisation
linéaire

Tests d'hypothèses

R


Références

Histogram of age




Âge

Histogramme des heures travaillées par semaine



Temps de travail

Histogramme des plus values




Plus values

Histogrammes


Source : apiacoa.org

Variables quantitatives uniques


Matthieu Falce



Âge



Temps de travail



Plus values

Densités

Source : apiacoa.org

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Variables quantitatives uniques

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données


Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références



Boxplot

Source : apiacoa.org

Variables quantitatives uniques

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données


Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références



Boxplot

Source : towardsdatascience.com

Variables quantitatives uniques

Matthieu Falce

- ▶ histogramme : estimation de la densité d'une variable
 - ▶ création : division en sous-intervalles et calcul des effectifs
 - ▶ idée de la distribution
- ▶ densité (par estimation)
 - ▶ utilisation d'estimateur par noyau (paramétrage possible)
 - ▶ peut présenter des instabilités si mauvais paramétrage
- ▶ *boxplot* (boîte à moustaches, boîte à pattes)
 - ▶ représentation compacte de la distribution
 - ▶ boîte : 1^{er} quartile, médiane, 3^e quartile
 - ▶ moustaches : $\max(\min(x), Q_1 - 1.5 \times \text{IQR})$ et $\min(\max(x), Q_3 + 1.5 \times \text{IQR})$ avec $\text{IQR} = Q_3 - Q_1$
 - ▶ représentation des *outliers*

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire


Tests d'hypothèses

R


Références

Variables quantitatives uniques

Matthieu Falce



- Moyenne : 40.44, Écart-type : 12.35
- Médiane : 40, Interquartile : 5
- Compléments :
 - 47 % = 40 heures
 - 29 % > 40 heures
 - 24 % < 40 heures



Comparaison des différentes techniques

Source : apiacoa.org

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Comparaison de distributions (conditionnement)

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références



- ▶ étudier une distribution conditionnelle
- ▶ combiner plusieurs distributions
- ▶ les boxplot sont bien adaptés

Techniques :

- ▶ comparaison de *boxplots*
- ▶ comparaison des densités
- ▶ comparaison des histogrammes
 - ▶ superposition
 - ▶ difficulté de lisibilité

Comparaison de distributions (conditionnement)

Matthieu Falce



Comparaison des différentes techniques pour la comparaison

Source : apiacoa.org

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Comparaison de distributions (conditionnement)

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données


Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références



Superposition d'histogrammes

Source : apiacoa.org

Variables quantitatives multiples

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

2 variables :

- ▶ diagramme de dispersion (*scatter plot*)
 - ▶ évolution combinée de deux variables

Variables quantitatives multiples

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données


Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références




Exemple de *scatter plot*

Source : apiacoa.org

Variables quantitatives multiples

Matthieu Falce



Exemple de matrice de *scatter plots*

Source : apiacoa.org

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire


Tests d'hypothèses

R

Références

Variables quantitatives multiples

Matthieu Falce



Exemple de matrice de corrélations

Source : apiacoa.org

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Variables quantitatives multiples

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Plus de 2 variables :

- ▶ matrice de scatter plots
 - ▶ tous les couples et histogrammes sur les diagonales
 - ▶ limité en quantité de variables à visualiser
- ▶ matrice de corrélations
 - ▶ heatmap (teinte représente la valeur de la corrélation)
 - ▶ meilleure densité de comparaison (on peut comparer plus de couples)

Variables qualitatives

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses


R

Références


- ▶ diagramme en bâtons (hauteur proportionnelle à la fréquence)
- ▶ camembert
 - ▶ difficilement lisible (comparaison de surfaces ou d'angles)
 - ▶ rester classique

Variables qualitatives

Matthieu Falce



Exemple de camembert



Exemple de diagramme en bâtons

Source : apiacoa.org

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Pièges à éviter

- ▶ graphiques tronqués
- ▶ échelles (log, log-log)
- ▶ graphiques 3d (perspectives)
- ▶ représentation distance / volume (infographies)
- ▶ données tronquées

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Pièges à éviter

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle


Modélisation linéaire

Tests d'hypothèses

R

Références

Exemples :




Source : <http://viz.wtf/image/171171167398>

Pièges à éviter

Matthieu Falce

Exemples :



Source : <http://viz.wtf/image/171134950336>

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Pièges à éviter

Exemples :

Cryptocurrencies Transaction Speeds Compared to Visa & Paypal



Source : valuewalk.com

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses


R

Références

Pièges à éviter

Matthieu Falce

Exemples :



Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R


Références

Source : <http://viz.wtf/image/165904464723>

Pièges à éviter

Matthieu Falce

Exemples :



Source : liverstories.com

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Pièges à éviter

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Critères de position

Critères de dispersion

Visualisation de données

Statistique Inférentielle


Modélisation linéaire

Tests d'hypothèses

R

Références

Exemples :



Source : livestories.com

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

**Statistique
Inférentielle**

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

Statistique Inférentielle

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

4- Statistique Inférentielle

4.1. Introduction

Jusqu'ici, on a fait comme si l'échantillon était la population

- ▶ « le panier moyen est de 49 € », « 4,2 % de conversion sur la page B », « 3 pièces défectueuses sur 50 »
 - ▶ ce sont des chiffres sur *ce qu'on a mesuré*
- ▶ mais ce qu'on veut connaître, c'est *la population* : tous les clients, toutes les visites à venir, toute la production
- ▶ et on n'en a vu qu'une partie : *un* tirage, parmi tous ceux qu'on aurait pu faire

Longtemps, la statistique, c'était le recensement : on mesurait tout. Quand on n'avait qu'un échantillon, on faisait comme s'il était la population. En 1908, William Gosset, brasseur chez Guinness, n'a que quatre ou cinq brassins pour comparer deux orges : il montre que le chiffre observé peut être loin de la vérité, et qu'il faut dire *de combien*. Il publie sous le pseudonyme *Student*.

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

Pourquoi ne pas confondre les deux ?

Matthieu Falce

- ▶ un autre tirage aurait donné un autre chiffre : 49 € est *une* valeur parmi celles qu'on aurait pu obtenir
- ▶ « 49 € sur 10 commandes » et « 49 € sur 10 000 commandes » ne veulent pas dire la même chose, et la statistique descriptive ne voit pas la différence
- ▶ sans mesurer cette incertitude, on ne distingue pas un effet réel d'un hasard du tirage
 - ▶ on déploie une page qui ne change rien
 - ▶ on abandonne un médicament qui marche
 - ▶ on change de fournisseur pour deux pièces défectueuses de plus

La statistique inférentielle traite l'échantillon comme un tirage, et accompagne chaque chiffre de son *incertitude* (intervalle de confiance) et chaque comparaison de son *risque d'erreur* (test).

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Et si j'ai toute la population ?

Matthieu Falce

« Nous, on a tous les détenus / tous les clients / toute la production : on ne peut faire que de la descriptive. »

- ▶ **vrai pour un inventaire** : « combien de clients de plus de 60 ans aujourd'hui ? » L'objet d'intérêt est exactement ce qu'on a mesuré, à l'instant T. Pas de tirage, pas d'incertitude, pas d'intervalle de confiance.
- ▶ **faux dès qu'on parle d'un mécanisme** : « 12 incidents cette année contre 8 l'an dernier, ça a augmenté ? », « le nouveau programme réduit-il les retours ? », « combien seront-ils l'an prochain ? » Rejouez l'année avec les mêmes conditions : vous n'obtenez pas 12 et 8. Les chiffres sont *une* réalisation d'un processus plein de hasard.

La population, ce n'est pas un ensemble de personnes : c'est *tout ce que le même processus aurait pu produire*. La question-test : *si je rejouais l'année, aurais-je exactement les mêmes chiffres ?* Si non, il y a du hasard, et mesurer ce hasard, c'est de l'inférence.

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

- ▶ **population** : ce qu'on veut connaître (tous les clients) ;
échantillon : ce qu'on a mesuré
- ▶ **paramètre** : la vraie valeur dans la population (μ, π), qu'on ne connaîtra jamais ; **estimation** : sa valeur dans l'échantillon ($\bar{x}, p$), qu'on connaît
- ▶ **inférer** : remonter de l'échantillon à la population. D'où *statistique inférentielle*.

L'approche de ce cours est dite *fréquentiste* (Fisher, Neyman, Pearson, années 1920-1930) : le hasard est dans le tirage, le paramètre est fixe, et « 95 % » veut dire « 95 fois sur 100 si on refaisait l'étude ». L'autre approche, *bayésienne*, met une probabilité sur le paramètre lui-même ; elle n'est pas au programme.

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Pourquoi des lois statistiques ?

Matthieu Falce

- ▶ un autre tirage donne un autre chiffre. Pour en tenir compte, il faut savoir quelles valeurs sont probables et lesquelles ne le sont pas
- ▶ une loi statistique, c'est ça : la probabilité de chaque valeur possible
- ▶ la loi normale est la plus utile : la moyenne d'un échantillon la suit, même quand les données ne la suivent pas (théorème central limite)

Suite de la section : lois usuelles, variabilité d'une moyenne d'échantillon, intervalle de confiance, taille d'échantillon.

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

4- Statistique Inférentielle

4.2. Lois statistiques connues

N'importe quelle fonction intégrable et à valeurs positives peut être utilisée comme loi statistique.

Certaines sont plus utiles que d'autres → modélisation / idéalisation de phénomènes

- ▶ loi uniforme
- ▶ loi gaussienne (ou loi normale)
- ▶ loi exponentielle
- ▶ loi log-normale
- ▶ loi du χ^2
- ▶

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Concepts

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon


Modélisation
linéaire

Tests d'hypothèses


R

Références


Histogramme de valeurs réparties
dans une loi exponentielle




Histogramme de valeurs réparties
dans une loi normale



Histogramme de valeurs réparties
dans une loi uniforme



Histogramme de valeurs réparties
dans une loi du χ^2 à 10 degrés de libertés



- ▶ fonction de répartition : probabilité que X soit inférieur à une valeur a ($P(X < a)$)
- ▶ fonction de probabilité : probabilité discrète que X soit égal à une valeur a ($P(X = a)$)
- ▶ distribution : valeurs obtenues quand une variable suit une loi statistique donnée (ce que l'on obtient avec ALEA dans Excel par exemple)

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R


Références

Loi normale


Matthieu Falce

Définie uniquement par sa moyenne (μ) et sa variance (σ^2) :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$



Fonction de probabilité de différentes lois normales



Fonction de répartition des mêmes lois normales

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Loi normale

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

- ▶ si moyenne vaut 0 ($\mu = 0$) $\rightarrow$ loi centrée
- ▶ si variance vaut 1 ($\sigma^2 = 1$) $\rightarrow$ loi réduite
- ▶ si les deux sont vérifiées en même temps $\rightarrow$ loi centrée réduite

Il est toujours possible de centrer réduire une loi gaussienne.

Loi *principale* des statistiques

La moyenne d'un échantillon de n individus tirés d'une même population suit approximativement une loi normale quand n est grand, quelle que soit la loi de la population.

Théorème central limite (TCL)

Par exemple : les montants des paniers d'une boutique ne suivent pas une loi normale (très asymétriques), mais la moyenne de 30 commandes tirées au hasard, recalculée sur des milliers de tirages, se répartit en cloche autour du vrai panier moyen (voir l'animation d'échantillonnage).


Règle des 68-95-99.7

Presque toutes les valeurs se situent à une *petite* distance de la moyenne.

$$\mathbb{P}(\mu - \sigma \leq x \leq \mu + \sigma) \approx 0.6827$$

$$\mathbb{P}(\mu - 2\sigma \leq x \leq \mu + 2\sigma) \approx 0.9545$$

$$\mathbb{P}(\mu - 3\sigma \leq x \leq \mu + 3\sigma) \approx 0.9973$$



Source : Wikipédia : Règle 68-95-99.7

Z-score

Pour une observation, le Z-score représente le nombre d'écarts-types d'écarts à la moyenne

$$Z_i = \frac{x_i - \bar{x}}{\sigma}$$

Permet de calculer les règles précédentes en utilisant uniquement les valeurs de la loi normale centrée réduite

Fonction de répartition

Matthieu Falce

$F(a) = P(X \leq a)$: la probabilité d'être *en dessous* de a .
C'est l'aire sous la courbe de densité à gauche de a ; l'aire totale vaut 1.

- ▶ c'est elle qu'on lit dans les tables et que les logiciels calculent : Excel `LOI.NORMALE.N(a;  $\mu$ ;  $\sigma$ ; VRAI)`, R `pnorm(a, mu, sigma)`
- ▶ entre deux bornes : $P(a < X \leq b) = F(b) - F(a)$.
Cure-dents : $P(56 < I < 64) = F(64) - F(56) \approx 0,95$
- ▶ dans l'autre sens, le *quantile* : quelle valeur n'est dépassée que 2,5 % du temps ? Excel `LOI.NORMALE.STANDARD.INVERSE(0,975)` = 1,96, R `qnorm(0.975)`. C'est de là que viennent le 1,96 des intervalles de confiance, et le 2,045 de la loi de Student à 29 degrés de liberté

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation linéaire


Tests d'hypothèses

R

Références

Fonction de répartition

Matthieu Falce



$P(X < -1,48) = F(-1,48) \approx 0,07$: l'aire colorée, à gauche de $-1,48$

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Fonction de répartition

Matthieu Falce

I	$\mathbb{P}(X \leq a)$		=> table
II	$\mathbb{P}(X \geq a)$	 = 1 - 	=> cas I
III	$\mathbb{P}(X \leq -a)$	 = 	=> cas II
IV	$\mathbb{P}(X \geq -a)$	 = 	=> cas I

Tout se ramène au cas I grâce à la symétrie :

$$P(X \geq a) = 1 - F(a) \text{ et } P(X \leq -a) = P(X \geq a)$$

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

4- Statistique Inférentielle

4.3. Intervalles de confiance

Ce que le hasard fait à une moyenne

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

On a résumé l'échantillon par une moyenne : 49 €.

- ▶ un autre tirage aurait donné une autre moyenne : la moyenne d'un échantillon est elle-même une *variable aléatoire*
- ▶ quelle est sa loi ? Si on la connaît, on sait à quelle distance de la vraie valeur on se trouve probablement

Ce que le hasard fait à une moyenne

Matthieu Falce

Expérience (animation [echantillonnage.html](#), dans votre dossier) :

1. une population connue : les 2000 paniers de la boutique (moyenne 49,12 €, très asymétrique)
2. on tire 30 commandes, on calcule la moyenne : une valeur
3. on recommence 1000 fois : les moyennes se répartissent *en cloche* autour de 49,12 €
4. l'écart-type de cette cloche vaut $\sigma/\sqrt{n}$: c'est *l'erreur standard*
5. on trace l'intervalle $\bar{x} \pm 2s/\sqrt{n}$ de chaque tirage : environ 95% d'entre eux contiennent 49,12 €

Trois idées à retenir : *variabilité d'échantillonnage, théorème central limite, intervalle de confiance.*

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

En mathématiques, un intervalle de confiance permet de définir une marge d'erreur entre les résultats d'un sondage et un relevé exhaustif de la population totale.

Plus généralement, l'intervalle de confiance permet d'évaluer la précision de l'estimation d'un paramètre statistique sur un échantillon.

[Wikipédia : Intervalle de confiance](#)

Intervalle de confiance

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

Exemple :

Un intervalle de confiance à 95% de la moyenne des durées de vie des ampoules testées est de [1230–1265].

Lecture correcte : *si l'on répétait l'expérience un grand nombre de fois, 95% des intervalles ainsi construits contiendraient la vraie durée de vie moyenne*. Celui-ci en fait partie ou non, on ne le sait pas.

Raccourci acceptable à l'oral : *on a confiance à 95% dans le fait que la moyenne de la population est entre 1230 et 1265*.


Les 5% restants sont le *risque α* : la part des intervalles qui ratent la vraie valeur.

Intervalle de confiance

Matthieu Falce

Importance de la valeur du risque sur l'intervalle de confiance

Nous avons 3 intervalles de confiance pour les risques 1, 5, 10 %.
Lequel est lequel ?



Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R


Références

Intervalle de confiance

Matthieu Falce

Importance de la taille de l'échantillon sur l'intervalle de confiance

Nous avons 3 intervalles de confiance à 5% pour des groupes de 10, 100, 1000 individus.
Lequel est lequel ?



Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Les intervalles de confiance les plus classiques sont

- ▶ intervalle de confiance des moyennes
- ▶ intervalle de confiance des différences de moyennes
- ▶ intervalle de confiance des écarts-types
- ▶ intervalle de confiance des proportions

Intervalle de confiance de la moyenne

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

Quelle est la confiance que nous pouvons apporter sur l'estimation de la moyenne de la population à partir de celle de notre échantillon ?

Ici, on part du principe que l'on ne connaît pas la variance *de la population*. On utilise alors l'estimateur non biaisé de la variance :

$$s_n^2 = \frac{n}{n-1} \sigma^2 \quad (s_n \simeq \sigma \text{ pour les } \textit{grands} \text{ échantillons})$$

On corrige à l'aide de la correction de Bessel¹ :

- ▶ on travaille sur le vecteur des résidus :
 $(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x})$
- ▶ on peut le voir comme n observations indépendantes, mais $n - 1$ résidus indépendants car leur somme vaut 0

Intervalle de confiance de la moyenne

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

Valeurs approchées (pour les grands échantillons ($n > 50$))

- ▶ intervalle de confiance à 68% : $\left[\bar{x} - 1 \frac{s}{\sqrt{n}}; \bar{x} + 1 \frac{s}{\sqrt{n}} \right]$
- ▶ intervalle de confiance à 95% : $\left[\bar{x} - 2 \frac{s}{\sqrt{n}}; \bar{x} + 2 \frac{s}{\sqrt{n}} \right]$ (valeur exacte : 1.96)
- ▶ intervalle de confiance à 99% : $\left[\bar{x} - 2.6 \frac{s}{\sqrt{n}}; \bar{x} + 2.6 \frac{s}{\sqrt{n}} \right]$ (valeur exacte : 2.58)

Ce sont les coefficients de la règle 68-95-99.7 vue pour la loi normale, appliqués à l'erreur standard $s/\sqrt{n}$.

Intervalle de confiance de la moyenne

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Calcul exact

$$\left[\bar{x} - t_{1-\alpha/2}^{n-1} \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2}^{n-1} \frac{s}{\sqrt{n}} \right]$$

où $t_{1-\alpha/2}^{n-1}$ est la valeur de la loi de Student à $n - 1$ degrés de liberté (le nombre d'observations - 1), estimée pour le quantile correspondant au risque $(1 - \frac{\alpha}{2})$.

dans les cas où le nombre d'échantillons est très grand, la loi de Student tend vers la loi normale centrée réduite

Il faut utiliser des tables ou des logiciels pour avoir ces valeurs exactes.

Intervalle de confiance de la moyenne

Matthieu Falce

Si l'on connaît la variance dans la population totale, on l'utilise
Calcul exact

$$\left[\bar{x} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right] \quad (1)$$

où $z_{1-\alpha/2}^{n-1}$ est la valeur de la loi de Normale.

Au final :

- ▶ on utilise la valeur de la variance connue (plus de correction sur la variance observée)
- ▶ on récupère la valeur d'une loi normale (plutôt que d'une loi de *Student*)
 - ▶ au final dans les deux cas, grand nombre d'échantillons (supérieur à 30, 50) → décile de loi normale

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Danger : valeurs individuelles - valeur moyenne

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

Ne pas confondre :

- ▶ intervalle de *prédiction* d'une valeur individuelle → prend en compte l'écart-type (ce n'est pas un intervalle de confiance)
- ▶ intervalle de confiance de la moyenne de la population → prend en compte l'écart-type *divisé par* $\sqrt{n}$

À écart-type (σ) égal, plus la taille de l'échantillon augmente, plus l'intervalle de confiance de la moyenne de la population se réduit (on augmente la précision avec le nombre d'observations)

Intervalle de confiance d'une différence de moyennes

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

$$IC_{\Delta} = (\bar{x}_1 - \bar{x}_2) \pm t_{1-\alpha/2}^{(n_1-1)+(n_2-1)} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

où $t_{1-\alpha/2}^{(n_1-1)+(n_2-1)}$ est la valeur de la loi de Student à $n_1 + n_2 - 2$ degrés de liberté (le nombre d'observations de l'échantillon 1 et 2 moins 2), estimée pour le quantile correspondant au risque $(1 - \frac{\alpha}{2})$. Ce nombre de degrés de liberté suppose des variances égales ; sinon, les logiciels (test de Welch, choisi par défaut dans R) calculent un nombre de degrés de liberté corrigé.

Intervalle de confiance d'une différence de moyennes

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Dans le cas où les échantillons ont même taille et même variance, la formule se simplifie :

$$IC_{\Delta} = (\bar{x}_1 - \bar{x}_2) \pm \sqrt{2} t_{1-\alpha/2}^{2n-2} \frac{s}{\sqrt{n}}$$

Dans le cas de gros échantillons, on peut utiliser les valeurs approchées de la loi de Student que l'on a vues avant.

Intervalle de confiance d'une proportion

Matthieu Falce

Quelle est la confiance que nous pouvons apporter sur l'estimation d'une proportion dans une population à partir de celle de notre échantillon ?

$$IC_{\pi} = p \pm z_{1-\alpha/2} \sqrt{\frac{p(1-p)}{n}} \quad (2)$$

où z est la valeur de la loi normale centrée réduite ($\mathcal{N}(0, 1)$) pour la valeur correspondant au quantile $1 - \alpha/2$.

Approximation valable si $np \geq 5$ et $n(1-p) \geq 5$. Sinon (proportions proches de 0 ou 1, petits échantillons), utiliser une méthode exacte : `prop.test` ou `binom.confint` dans R.

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

- ▶ la valeur dans la population peut se situer n'importe où dans l'intervalle de confiance
- ▶ il ne faut pas faire d'hypothèse sur la distribution dans l'IC
- ▶ un intervalle de confiance à 95%
 - ▶ ne permet pas de penser que 95% des observations futures seront dedans (c'est le rôle de l'intervalle de prédiction)
 - ▶ ne signifie pas que *la probabilité que la valeur réelle soit dans l'intervalle* est 95% (la valeur réelle n'est pas une variable aléatoire)
 - ▶ mais signifie que *la méthode* qui a produit cet intervalle capture la vraie valeur dans 95% des études (lecture fréquentiste vue plus haut)

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalles de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

4- Statistique Inférentielle

4.4. Taille d'échantillon

Faut-il toujours un grand échantillon ?

- ▶ réponses pertinentes malgré un échantillon non représentatif de la population générale
 - ▶ sondages satisfaction client
 - ▶ même peu nombreux, retours pertinents
- ▶ nécessité de refléter la population globale : sondages d'opinion politiques
- ▶ différence entre un retour qualitatif et quantitatif
- ▶ si l'échantillon fait la taille de la population → problèmes
- ▶ penser aux analyses futures pour ne pas avoir de sous-échantillons trop petits

Caractéristique de la population mère

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

- ▶ taille de la population mère
 - ▶ grande population → échantillon de grande taille
 - ▶ mais si très grandes populations → asymptote, peu d'importance
 - ▶ un échantillon de 1000 personnes aux États-Unis a la même fiabilité qu'un échantillon de même taille en France
- ▶ variabilité dans la population mère
 - ▶ population ayant une grande variabilité → échantillon de grande taille
 - ▶ peu de variabilité → échantillon plus petit
 - ▶ cas limite : si tous les individus sont identiques, échantillon d'un individu

- ▶ déterminer la taille de la population
- ▶ définir la marge d'erreur, ou intervalle de confiance (par exemple $35\% \pm 5\%$)
- ▶ définir le niveau de confiance : mesure le degré de certitude que l'échantillon représente correctement la population dans une marge d'erreur définie (c'est $1 - \alpha$, par exemple 95% pour un risque α de 5%)
- ▶ calculer l'écart-type (difficile à déterminer avant la réalisation de l'enquête, si on ne le connaît pas, on prend 0.5 dans le cas d'une estimation de proportion pour avoir le pire des cas)
- ▶ utiliser les formules de calculs

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Formule – taille échantillon pour estimer une proportion

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Population de taille connue

$$n = \frac{z^2 \cdot \frac{p(1-p)}{e^2}}{1 + \frac{z^2 \cdot p(1-p)}{e^2 \cdot N}}$$

avec :

- ▶ n = taille de l'échantillon
- ▶ N = taille de la population
- ▶ z = z-score au niveau de confiance fixé
- ▶ e = marge d'erreur
- ▶ p = proportion attendue ($p(1 - p)$ est la variance d'une proportion, maximale pour $p = 0.5$)

Formule – taille échantillon pour estimer une proportion

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Population de taille inconnue ou très grande ($N \rightarrow \text{inf}$)

$$n = z^2 \frac{p(1-p)}{e^2} \quad (3)$$

avec :

- ▶ n = taille de l'échantillon
- ▶ z = z-score au niveau de confiance fixé
- ▶ e = marge d'erreur
- ▶ p = proportion attendue (0.5 si on ne sait rien : pire des cas)

Formule – taille échantillon pour estimer une proportion

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation
linéaire

Tests d'hypothèses

R

Références

Formule de Slovin : cas particulier de la formule précédente avec $p = 0,5$ et $z \approx 2$ (niveau de confiance implicite de 95%)

$$n = \frac{N}{1 + N.e^2}$$

avec :

- ▶ n = taille de l'échantillon
- ▶ N = taille de la population
- ▶ e = marge d'erreur

Formule – taille échantillon pour estimer une moyenne

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Introduction

Lois statistiques connues

Intervalle de confiance

Taille d'échantillon

Modélisation linéaire

Tests d'hypothèses

R

Références

Population de taille inconnue ou très grande ($N \rightarrow \text{inf}$)

$$n = \frac{z^2 \cdot s^2}{e^2} \quad (4)$$

avec :

- ▶ n = taille de l'échantillon
- ▶ z = z-score au niveau de confiance fixé (1.96 pour un taux de confiance à 95%)
- ▶ e = marge d'erreur sur la moyenne, exprimée dans la même unité que la moyenne

Lien entre les formules :

- ▶ la formule de la taille d'échantillon pour une moyenne (équation 4) s'obtient en isolant n dans la demi-largeur de l'intervalle de confiance d'une moyenne (équation 1) :

$$e = z \frac{s}{\sqrt{n}}$$

- ▶ la formule pour une proportion (équation 3) s'obtient de la même façon à partir de l'intervalle de confiance d'une

proportion (équation 2) :
$$e = z \sqrt{\frac{p(1-p)}{n}}$$

- ▶ autrement dit : *choisir une taille d'échantillon, c'est choisir la précision que l'on veut*

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

**Modélisation
linéaire**

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Modélisation linéaire

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

5- Modélisation linéaire

5.1. Qu'est-ce qu'un modèle ?

Un modèle, c'est une phrase simple sur le monde

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

... dont on mesure à quel point elle est fausse.

la phrase (le modèle)	ce qu'elle prédit	comment on mesure l'erreur
« le panier moyen est de 49 € » « le CA monte de 4,5 € par euro de pub » « les deux pages convertissent pareil » « les paniers suivent une loi normale »	49 € pour chaque commande un CA pour chaque budget même taux pour A et B des effectifs par classe	écart-type (49 € $\pm$ 31 €) résidus, écart-type résiduel p -value du χ^2 χ^2 d'adéquation

Un modèle, c'est une phrase simple sur le monde

Matthieu Falce

... dont on mesure à quel point elle est fausse.

Toujours la même boucle :

1. écrire la phrase (choisir le modèle)
2. estimer ses paramètres sur les données (*apprentissage*)
3. mesurer l'erreur : le modèle tient-il ? (*adéquation*)
4. s'en servir pour dire quelque chose de nouveau (*prédiction*)

La statistique descriptive fait 1 et 2.

La statistique inférentielle fait 3 et 4 en tenant compte du hasard.

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Un modèle, c'est une phrase simple sur le monde

Matthieu Falce

... dont on mesure à quel point elle est fausse.

Tous les modèles sont faux, certains sont utiles.

George Box

Un modèle utile : assez simple pour être compris et expliqué,
assez juste pour que son erreur soit acceptable *pour la*
décision à prendre.

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

5- Modélisation linéaire


5.2. Régression linéaire simple

Une question métier

Matthieu Falce

La direction hésite à passer le budget publicitaire hebdomadaire de 3 000 € à 6 000 €.

Que peut-on lui promettre ?



Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R


Références

Une question métier

Matthieu Falce

La direction hésite à passer le budget publicitaire hebdomadaire de 3 000 € à 6 000 €.

Que peut-on lui promettre ?



Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

$$y = a + bx + \varepsilon$$

- ▶ y : la variable *expliquée* (réponse) : le chiffre d'affaires
- ▶ x : la variable *explicative* : le budget
- ▶ b : la *pente*, a : l'*ordonnée à l'origine* : les paramètres à estimer
- ▶ ε : l'*erreur*, tout ce que le modèle n'explique pas

Pour chaque semaine i , le *résidu* est l'écart entre ce qu'on a vu et ce que la droite prédit :

$$e_i = y_i - (a + bx_i)$$

La droite des moindres carrés

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir


Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références



La droite des moindres carrés

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

On choisit a et b pour que la *somme des carrés des résidus* soit la plus petite possible :

$$\min_{a,b} \sum_{i=1}^n e_i^2$$

- ▶ même idée que la variance : on somme des carrés pour que les écarts ne s'annulent pas
- ▶ la solution a une formule fermée, le logiciel la calcule :
$$b = \frac{\text{Cov}(x, y)}{\text{Var}(x)}, \quad a = \bar{y} - b\bar{x}$$
- ▶ la droite passe toujours par le point moyen $(\bar{x}, \bar{y})$

$$CA = 17\,165 + 4,49 \times \text{budget}$$

- ▶ **pente** $b = 4,49$: *une semaine à 1 € de budget de plus a fait, en moyenne, 4,49 € de CA de plus.* Son unité : € de CA par € de budget.
- ▶ **ordonnée à l'origine** $a = 17\,165$: le CA « prévu » à budget nul. Souvent hors de la zone observée (aucune semaine à 0 €) : à lire avec prudence.
- ▶ chaque coefficient a son **intervalle de confiance** : pente entre 4,03 et 4,95 à 95%. Si l'IC contient 0, la variable n'apporte rien de démontrable.

Excel

PENTE, ORDONNEE.ORIGINE, DROITEREG (avec les erreurs standard), courbe de tendance

R

lm(ca ~ budget), summary, confint

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

R^2 : la part expliquée

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

$$R^2 = 1 - \frac{\sum e_i^2}{\sum (y_i - \bar{y})^2} = \frac{\text{variance expliquée par la droite}}{\text{variance totale de } y}$$

- ▶ entre 0 (la droite n'explique rien) et 1 (tous les points sont dessus)
- ▶ pour une seule variable explicative, $R^2 = r^2$, le carré du coefficient de corrélation
- ▶ $R^2 = 0,89$: 89% des différences de CA d'une semaine à l'autre « suivent » le budget ; les 11% restants sont ailleurs (saison, météo, concurrence, hasard)

R^2 : la part expliquée

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références



Ce que R^2 ne dit *pas* :

- ▶ si la relation est linéaire (regarder les résidus)
- ▶ si la prévision est précise en euros (regarder l'écart-type résiduel : ici 2410 €)
- ▶ si x *cause* y

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

5- Modélisation linéaire

5.3. Lire les résidus

Les résidus disent si le modèle tient

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire


Tests d'hypothèses

R

Références

On trace les résidus en fonction des valeurs prédites.


On veut *ne rien voir*.



- **courbure** : la relation n'est pas une droite (ajouter un terme, passer au log, changer de modèle)
- **éventail** : l'erreur grandit avec x ; les intervalles de prédiction seront faux d'un côté
- **points isolés** : une semaine exceptionnelle tire la droite; comprendre pourquoi avant de l'enlever

Les résidus de la boutique

Matthieu Falce



- ▶ pas de structure, dispersion constante, histogramme symétrique
- ▶ l'**écart-type résiduel** (2 410 €) est l'erreur *typique* du modèle sur une semaine : c'est lui qui pilote la précision des prévisions

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

5- Modélisation linéaire

5.4. Prévoir

Deux questions, deux intervalles

Pour un budget $x_0 = 6\,000$ €, la droite donne $\hat{y}_0 = 44\,100$ €.
Mais :

- **quel est le CA moyen des semaines à 6 000 € ?** →
intervalle de confiance de la moyenne : $[42\,900; 45\,300]$
- **quel sera le CA de la semaine prochaine à 6 000 € ?** →
intervalle de prédiction : $[39\,100; 49\,100]$

$$\text{confiance : } \hat{y}_0 \pm t_{1-\alpha/2}^{n-2} s_{res} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x_i - \bar{x})^2}}$$

$$\text{prédiction : } \hat{y}_0 \pm t_{1-\alpha/2}^{n-2} s_{res} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x_i - \bar{x})^2}}$$

s_{res} : l'écart-type résiduel (ici 2 410 €), n : le nombre de semaines (52),

$t_{1-\alpha/2}^{n-2}$: la valeur de Student, ≈ 2 .

Le « $1 +$ » est le bruit de la semaine elle-même : l'intervalle de prédiction ne se resserre jamais en dessous de $\pm 2 s_{res}$, même avec des années de données.

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire


Tests d'hypothèses

R

Références

Deux questions, deux intervalles

Matthieu Falce



Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Deux questions, deux intervalles

Matthieu Falce



Extrapolation : le modèle a été ajusté entre 1 570 et 6 480 € de budget.

À 12 000 €, rien ne dit que la relation reste linéaire (saturation, enchères plus chères).

On refuse, ou on encadre très fortement.

Association, pas causalité : « les semaines à gros budget ont fait plus de CA » n'est pas « la pub fait le CA » (la saison tire peut-être les deux). Pour le démontrer : faire varier le budget de façon contrôlée.

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

5- Modélisation linéaire

5.5. Adéquation à un modèle

Le modèle tient-il ? Observé contre attendu

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Même question pour une loi que pour une droite : on compare ce que le modèle prédit à ce qu'on a vu.

classe de panier (€)	observé	attendu si normale	attendu si log-normale
[0, 25[	342	437	362
[25, 50[	947	586	889
[50, 75[	400	573	451
[75, 100[	174	303	177
[100, 150[	111	100	98
[150, 300[	26	1	23

La loi normale se trompe d'un facteur 2 sur trois classes et prédit 113 paniers négatifs. La log-normale colle à 5-10% près.

Le modèle tient-il ? Observé contre attendu

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Même question pour une loi que pour une droite : on compare ce que le modèle prédit à ce qu'on a vu.

Outils :

- ▶ χ^2 **d'adéquation** : $\sum \frac{(\text{observé} - \text{attendu})^2}{\text{attendu}}$, degrés de liberté = classes - 1 - paramètres estimés
- ▶ **QQ-plot** : quantiles observés contre quantiles théoriques ; une droite si la loi convient
- ▶ **tests de normalité** (Shapiro-Wilk) : avec 2000 observations ils rejettent tout, regarder le graphique d'abord



Règle pratique : *la normalité compte pour les moyennes (TCL) et pour les résidus, presque jamais pour la variable brute.*

Le panier n'est pas normal, et l'IC du panier moyen est quand même bon.

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

5- Modélisation linéaire

5.6. Tout est un modèle linéaire

Student et l'ANOVA sont des régressions

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir


Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références



Student et l'ANOVA sont des régressions

Matthieu Falce

Remplacer x par une variable *qualitative* (le canal) revient à ajuster *une moyenne par groupe* :

$$\text{montant} = \mu_{\text{canal}} + \varepsilon$$

- ▶ 2 groupes : c'est le test de Student (la pente est la différence des moyennes)
- ▶ k groupes : c'est l'ANOVA (le test F compare la variance *entre* groupes à la variance *dans* les groupes, c'est-à-dire aux résidus)
- ▶ en R, `aov(montant ~ canal)` et `lm(montant ~ canal)` sont le même calcul

Un seul outil pour tout le jour 2 : *un modèle, ses résidus, une p-value.*

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Student et l'ANOVA sont des régressions

Matthieu Falce

Et en R, tout tient en cinq lignes :

```
ca = read.table("caHebdo.csv", sep=";", dec=".", header=TRUE)

# ajuster le modèle : CA expliqué par le budget
modele = lm(chiffre_affaires_eur ~ budget_pub_eur, data=ca)
summary(modele)
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   17165.184   1062.53    16.15  <2e-16 ***
## budget_pub_eur    4.489     0.228    19.69  <2e-16 ***
## Residual standard error: 2410 on 50 degrees of freedom
## Multiple R-squared:  0.8856

confint(modele)           # IC à 95 % des coefficients

# prévoir pour un budget de 6000 €
nouveau = data.frame(budget_pub_eur=6000)
predict(modele, nouveau, interval="confidence") # CA moyen
predict(modele, nouveau, interval="prediction")  # une semaine

# vérifier le modèle : les 4 graphiques de diagnostic
par(mfrow=c(2, 2)); plot(modele)
```

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Linéaire en quoi ? Et au-delà

Matthieu Falce

- ▶ linéaire *dans les coefficients*, pas dans x :
 $y = a + bx + cx^2 + \varepsilon$ ou $y = a + b \log(x) + \varepsilon$ sont des modèles linéaires. Même calcul, même lecture des résidus.
Une courbure dans les résidus, c'est un terme à ajouter
- ▶ plusieurs variables : $CA = a + b \text{budget} + c \text{saison} + \varepsilon$. Même outil : `lm(ca ~ budget + saison)`, `DROITEREG` sur plusieurs colonnes
- ▶ vraiment non linéaire : $y = a e^{bx}$, saturation. `nls` dans R ; souvent, un logarithme ramène au cas linéaire
- ▶ réponse oui/non ou comptage (achat, nombre d'incidents) : régression logistique, de Poisson (`glm`). Le test A/B est une régression logistique à une variable

Dans tous les cas, ε est ce qui reste, et doit ressembler à du bruit : même dispersion partout, pas de structure, indépendant d'une observation à l'autre.

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Qu'est-ce qu'un modèle ?

Régression linéaire simple

Lire les résidus

Prévoir

Adéquation à un modèle

Tout est un modèle linéaire

Tests d'hypothèses

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Tests d'hypothèses

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

6- Tests d'hypothèses

6.1. Hypothèses

Hier, aujourd'hui

Matthieu Falce

- ▶ hier : décrire, donner un chiffre avec son incertitude, modéliser et prévoir
- ▶ la question qui reste, posée partout : *cet écart est-il réel, ou c'est le hasard du tirage ?*
 - ▶ 1,1 point de conversion entre les pages A et B
 - ▶ 0,5 °C entre deux groupes de patients
 - ▶ une pente de 4,49 € par euro de pub : et si c'était 0 ?
- ▶ l'intervalle de confiance répond déjà en partie : s'il contient 0, on ne peut rien affirmer
- ▶ aujourd'hui : une procédure pour répondre oui ou non, avec un risque d'erreur qu'on choisit. C'est le test d'hypothèse, la même idée que l'intervalle de confiance, présentée autrement

On commence avec une pièce de monnaie.

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Une pièce est-elle truquée ?

Matthieu Falce

- ▶ je lance une pièce 10 fois, j'obtiens 7 piles : est-elle truquée ?
 - ▶ pas forcément : une pièce normale fait au moins 7 piles sur 10 environ une fois sur six
- ▶ je la lance 100 fois, j'obtiens 70 piles
 - ▶ avec une pièce normale, cela n'arrive quasiment jamais (moins d'une fois sur 20 000) : je conclus qu'elle est truquée

Le raisonnement : je fais *comme si* la pièce était normale, et je regarde si ce que j'observe serait courant ou exceptionnel.

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Le même raisonnement qu'un procès

Matthieu Falce

- ▶ l'accusé est présumé innocent : on part de l'hypothèse « il n'a rien fait »
- ▶ on ne le condamne que si les preuves rendent cette hypothèse difficile à croire
- ▶ acquitté ne veut pas dire innocent : les preuves ne suffisaient pas

Un échantillon ne donne jamais de certitude : on peut montrer que les données collent mal avec une hypothèse, pas qu'elles la prouvent.

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Exemple : un médicament contre la fièvre

Matthieu Falce

- ▶ 40 malades, répartis au hasard en deux groupes de 20
- ▶ placebo : 38,9 °C en moyenne ; médicament : 38,4 °C en moyenne
- ▶ 0,5 °C d'écart : effet du médicament, ou hasard du tirage ?
- ▶ H_0 : le médicament ne change rien, les vraies moyennes sont égales ($\mu_1 = \mu_2$)
- ▶ H_1 : il change quelque chose ($\mu_1 \neq \mu_2$), en mieux ou en pire

Si H_0 était vraie, verrait-on souvent un écart de 0,5 °C entre deux groupes de 20 ?

- ▶ rarement : je rejette H_0
- ▶ souvent : je ne peux pas conclure

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Exemple : un médicament contre la fièvre

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Pour répondre, trois nombres par groupe suffisent : la moyenne, l'écart-type s (ici 0,46 et 0,50 °C), l'effectif n .

$$t = \frac{\text{écart}}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} = \frac{0,5}{\sqrt{\frac{0,46^2}{20} + \frac{0,50^2}{20}}} = 3,3$$

L'écart vaut 3,3 fois ce que le hasard du tirage produit typiquement. Si H_0 était vraie, ça arriverait 2 fois sur 1 000 ($p = 0,002$) : je rejette H_0 . C'est le TP 2.3.

Sous la racine : les *variances* s^2 (en °C²) divisées par n ; la racine ramène en °C. C'est l'erreur standard de l'écart.

- ▶ hypothèse nulle (H_0)
 - ▶ *pas d'effet* : les paramètres des *populations* sont égaux ($\mu_1 = \mu_2$)
 - ▶ μ_1 et μ_2 sont les vraies moyennes, qu'on ne connaîtra jamais ; on ne voit que les moyennes des échantillons, qui sont toujours un peu différentes
 - ▶ la question n'est pas « y a-t-il une différence ? » (il y en a toujours une) mais « est-elle trop grande pour venir du seul hasard du tirage ? »
- ▶ hypothèse alternative (H_1)
 - ▶ tout le reste : $\mu_1 \neq \mu_2$, ou seulement $\mu_1 > \mu_2$, ou seulement $\mu_1 < \mu_2$
- ▶ on raisonne *comme si* H_0 était vraie, et on regarde si les données sont crédibles dans ce cadre
- ▶ on dit : *je rejette H_0 au profit de H_1*
- ▶ on ne dit pas *j'accepte H_0 mais je ne peux pas la rejeter*

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Autre exemple : un test dans un seul sens

Matthieu Falce

- ▶ je fabrique des ampoules, je veux savoir si elles durent plus longtemps que celles de mon concurrent
- ▶ je mesure la durée de vie de 50 de mes ampoules et de 50 des siennes
- ▶ H_0 : mes ampoules ne durent pas plus longtemps ($\mu_1 \leq \mu_2$)
- ▶ H_1 : mes ampoules durent plus longtemps ($\mu_1 > \mu_2$)
- ▶ seul un écart en ma faveur peut me faire rejeter H_0 : c'est un test *unilatéral*

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Ne pas rejeter n'est pas accepter

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Le non-rejet de l'hypothèse nulle n'implique pas qu'il n'y a pas d'effet.

Juste que l'on n'en a pas vu (échantillon trop petit, mesures trop dispersées...).

Absence de preuve n'est pas preuve d'absence

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

6- Tests d'hypothèses

6.2. Risques d'erreur

Et si je me trompe ?

Matthieu Falce

Retour au médicament : à la fin du test, je conclus « il marche » (je rejette H_0) ou « je n'ai rien vu » (je ne rejette pas H_0).

- ▶ **faux positif** : je conclus « il marche » alors qu'il ne fait rien
 - ▶ on commercialise un médicament inutile
- ▶ **faux négatif** : je conclus « rien vu » alors qu'il marche
 - ▶ on abandonne un médicament qui marche
 - ▶ c'est l'*absence de preuve* de tout à l'heure

Dans les livres, on trouve aussi : erreur de première espèce, de type I ou α (faux positif) ; erreur de seconde espèce, de type II ou β (faux négatif).

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Sur 100 études

Matthieu Falce

je conclus	le médicament ne fait rien (H_0 vraie)	le médicament marche (H_0 fausse)
« rien vu »	correct : 95 sur 100	faux négatif : 20 sur 100 (β)
« il marche »	faux positif : 5 sur 100 (α)	correct : 80 sur 100 (<i>puissance</i>)

- ▶ chaque *colonne* fait 100 : le tableau se lit de haut en bas
- ▶ je *choisis* α avant l'étude (5 % en général)
- ▶ β dépend du nombre de patients, de la taille de l'effet et de la variabilité des données
- ▶ je ne sais jamais dans quelle colonne je suis : c'est l'état réel du médicament que j'ignore

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Le piège de lecture

Matthieu Falce

$\alpha = 5\%$ ne veut pas dire « 5 % de mes résultats positifs sont faux ».

On teste 1 000 médicaments, dont 100 marchent vraiment ($\alpha = 5\%$, puissance 80 %) :

- ▶ sur les 100 qui marchent : 80 détectés
- ▶ sur les 900 qui ne font rien : 45 faux positifs (5 % de 900)

125 résultats « il marche », dont 45 faux : **36 %**. α est la probabilité de dire « il marche » quand il n'y a rien, pas celle de se tromper quand on a dit « il marche ».

Animation [risques.html](#), dans votre dossier : les 1 000 médicaments, ce que voit le chercheur, et ce qui se passe quand 1 % seulement marchent.

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Le même tableau, ailleurs

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Contrôle qualité dans l'industrie automobile

		Défaut détecté	
		oui	non
Défaut présent	oui (cas rare)	vrai positif (portière mal montée et détectée comme mal montée)	faux négatif (portière mal montée et non détectée => on laisse passer un défaut)
	non (cas principal)	faux positif (on détecte une portière comme mal montée alors que c'est bon)	vrai négatif (on ne fait rien s'il n'y a pas de défauts)

- cas idéal
- on laisse passer un défaut
- on déclenche une fausse alerte

Le même tableau, ailleurs

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Source : Twitter, @freakonometrics

$$\hat{Y} = 0$$

NEGATIVE

$$\hat{Y} = 1$$

POSITIVE

$$Y = 0$$

NOT PREGNANT



$$Y = 1$$

PREGNANT



Faux positifs ou faux négatifs ?

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R


Références

Comme dans un procès :

- ▶ exiger plus de preuves pour condamner : moins d'innocents en prison, mais plus de coupables acquittés
- ▶ à données égales, baisser α fait monter β , et inversement
- ▶ plus d'observations, c'est un dossier plus épais : les deux erreurs baissent

Faux positifs ou faux négatifs ?

Matthieu Falce



Source : Wikipédia : Test statistique

- ▶ en noir, les résultats possibles si le médicament ne fait rien ; en bleu, s'il marche
- ▶ au-delà du seuil S , je conclus « il marche »
- ▶ décaler S vers la droite réduit α (gris) et agrandit β (bleu clair)
- ▶ plus de patients : les deux courbes s'affinent et se chevauchent moins
- ▶ à manipuler : [animation alpha_beta.html](#), dans votre dossier

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

La puissance

Matthieu Falce

- ▶ la probabilité de détecter un effet qui existe vraiment ($1 - \beta$)
- ▶ il n'y a pas *un* β mais un par taille d'effet : un gros effet se voit plus facilement qu'un petit
- ▶ la taille de l'effet compte par rapport à la variabilité des données
 - ▶ 0,5 °C d'écart se voit facilement si tous les patients ont la même fièvre à 0,1 °C près
 - ▶ beaucoup moins si elle varie de 2 °C d'un patient à l'autre

Pour calculer le nombre de patients, on fixe :

- ▶ α (5 % en général)
- ▶ la puissance voulue (80 % en général)
- ▶ le plus petit effet qu'on veut pouvoir détecter

et on estime la variabilité (étude pilote, données passées).

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

6- Tests d'hypothèses

6.3. Valeur p

Valeur P (*p-value*)

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Certains logiciels renvoient une valeur-p (*p-value*) à la place d'un intervalle de confiance.

Probabilité d'observer un événement au moins aussi extrême si on suivait H_0

Cette valeur doit être inférieure au risque α pour que l'on puisse rejeter H_0

- ▶ si la *p-value* est $< \alpha$: on rejette $H_0 \rightarrow$ si H_0 était vraie, un écart au moins aussi grand serait rare (moins de α des fois)
- ▶ si la *p-value* est $> \alpha$: on ne peut pas rejeter $H_0 \rightarrow$ un tel écart n'a rien de surprenant si H_0 est vraie ; on n'a pas vu d'effet

Attention :

- ▶ la valeur p n'indique en rien la taille de l'effet mesuré → juste si l'écart observé est *surprenant* sous H_0 (ce n'est *pas* la probabilité que H_0 soit vraie, ni que la différence existe)
 - ▶ comme au saut à la perche, on regarde si l'athlète a dépassé la barre ou pas, pour une hauteur fixée à l'avance
- ▶ les intervalles de confiance encadrent eux la valeur → permettent une meilleure compréhension de ce qui se passe dans certains cas (mise en avant de la valeur de l'effet)
- ▶ les intervalles de confiance ne considèrent pas la taille de la population, juste celle de l'échantillon (on n'a pas forcément accès à la taille de la population)

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

6- Tests d'hypothèses

6.4. Tests statistiques courants

Définition

Matthieu Falce

- ▶ processus de prise de décision
- ▶ rejeter, ou non, une hypothèse nulle
- ▶ un test permet de poser une question spécifique sur la population à partir de l'échantillon
- ▶ renvoie une *p-value*

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Tests unilatéraux et bilatéraux

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p


Tests statistiques courants

Bestiaire


R

Références


Test à unilatéral à gauche



Test bilatéral



Test unilatéral à droite



Différents types de tests (qui partagent la même *p-value*) de 5%

Tests unilatéraux et bilatéraux

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

- ▶ tests bilatéraux :
 - ▶ on teste une différence des deux côtés
 - ▶ peu importe que la différence soit positive ou négative
- ▶ tests unilatéraux :
 - ▶ on teste une différence spécifique (groupe 1 est plus petit que groupe 2)
 - ▶ ces tests sont plus *puissants* si l'on sait *avant de voir les données* que seul un sens nous intéresse (on utilise toute la valeur de risque et pas $\alpha/2$)
 - ▶  choisir le sens *après* avoir regardé les données revient à tricher sur le risque

Test de Student ou test de t (t -test)

Cas d'utilisation

- ▶ comparaison d'une moyenne d'un échantillon à une valeur (la variance de la population est *inconnue*, on l'estime avec s ; si elle est connue, on parle de test z)
- ▶ comparaison de 2 moyennes issues de deux échantillons (mesure si la différence est nulle)
- ▶ test sur échantillons appariés (on mesure un individu avant et après un traitement) (s'intéresse à la moyenne des différences)

Condition d'utilisation

- ▶ distribution normale (si petit échantillon)
- ▶ *vérifier qu'il n'y a pas de valeurs aberrantes*

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Exemple de calcul (comparaison d'un échantillon à une moyenne) :

Comme dans tous les tests paramétriques, on part du principe que ce que nous observons suit une loi théorique et nous comparons la valeur observée à la valeur théorique.

- ▶ on calcule la statistique de *t observée* :
$$t_{\text{observée}} = \frac{m - \mu}{\frac{s}{\sqrt{n}}}$$
- ▶ on regarde la statistique de *t théorique* : table de la loi de t / Student avec comme degré de liberté le nombre d'observations moins un et la valeur de risque voulue ($t_{1-\alpha/2}^{n-1}$)
- ▶ si $|t_{\text{observée}}| > t_{\text{thorique}}$ alors la différence est significative
- ▶ sinon ($|t_{\text{observée}}| < t_{\text{thorique}}$) on ne peut pas observer de différence

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Cas d'utilisation :

- ▶ tester l'indépendance entre deux variables catégorielles (χ^2 d'indépendance ou χ^2 de Pearson)
- ▶ tester l'adéquation d'une variable à une loi de probabilité (χ^2 d'adéquation)
- ▶ tester si des échantillons sont issus d'une même population (χ^2 d'homogénéité)

Calcul d'un χ^2 d'homogénéité

Pour les nouveaux packagings, le service *marketing* veut savoir si les couleurs préférées des enfants et des ados sont différentes. On veut savoir si la répartition des couleurs est la même entre les groupes.

Table de contingence (valeurs observées) :

	bleu	rouge	vert	total
enfants	11	20	15	46
ados	7	23	14	44
total	18	43	29	90

Table de contingence (valeurs théoriques) :

	bleu	rouge	vert	total
enfants	$\frac{18 \times 46}{90}$	$\frac{43 \times 46}{90}$	$\frac{29 \times 46}{90}$	46
ados	$\frac{18 \times 44}{90}$	$\frac{43 \times 44}{90}$	$\frac{29 \times 44}{90}$	44
total	18	43	29	90

Calcul d'un χ^2 d'homogénéité

Effectifs attendus si la répartition était la même (total ligne
× total colonne / 90) :

	bleu	rouge	vert	total
enfants	9,2	22,0	14,8	46
ados	8,8	21,0	14,2	44
total	18	43	29	90

► χ^2 observé :

$$\sum_{i,j} \frac{(\text{observé}_{ij} - \text{attendu}_{ij})^2}{\text{attendu}_{ij}} = \frac{(11-9,2)^2}{9,2} + \frac{(20-22,0)^2}{22,0} + \dots = 1,09$$

► degrés de liberté : $(\text{lignes} - 1) \times (\text{colonnes} - 1) = 2$; seuil à 5 % dans la table : 5,99 ; $p = 0,58$

► $1,09 < 5,99$: on ne rejette pas H_0 ; rien ne montre une préférence différente. Avec 90 réponses, un petit écart ne se verrait pas

► R : `chisq.test(matrix(c(11, 20, 15, 7, 23, 14), 2, byrow = TRUE))` ; Excel : `CHISQ.TEST(observés; attendus)`

ANalysis Of VAriance

- ▶ On étudie le comportement d'une variable quantitative en fonction de variable(s) catégorielle(s)
- ▶ On va comparer les *moyennes* entre les groupes

Hypothèses du test :

$$\begin{cases} H_0 : m_1 = m_2 = \dots = m_k = m \\ H_1 : \exists(i,j) \text{ tel que } m_i \neq m_j \end{cases}$$



L'ANOVA ne permet pas de savoir quel est le groupe différent.

Il faut utiliser d'autres tests pour ça (test de Tukey par exemple)

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Origine du nom

Décomposition de la variance en :

- ▶ variance *intra* : la variance à l'intérieur d'un groupe
- ▶ variance *inter* : la variance entre les groupes

L'ANOVA peut modéliser une réponse en fonction de plusieurs critères, on parle d'ANOVA à plusieurs facteurs

- ▶ on teste l'influence des différents facteurs séparément
- ▶ on teste l'influence des *interactions* entre les facteurs

Hypothèses à respecter

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Les modèles linéaires nécessitent le respect de certaines hypothèses :

- ▶ indépendance des erreurs
- ▶ variables explicatives non corrélées aux termes d'erreurs
- ▶ normalité des termes d'erreur
- ▶ homoscedasticité (les termes d'erreurs sont à variance constante)

Hypothèses à respecter

Matthieu Falce

Le non-respect de ces hypothèses peut :

- ▶ ne pas avoir d'impact
- ▶ indiquer qu'il y a d'autres dépendances dans les données
- ▶ remettre en cause la validité des conclusions



- ▶ il faut jeter un oeil aux résidus et aux données pour vérifier la validité des hypothèses
- ▶ dans certains cas, on peut utiliser des tests non-paramétriques (hors programme) qui n'ont pas toutes ces hypothèses

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

6- Tests d'hypothèses

6.5. Bestiaire

Quel test statistique utiliser ? I

Matthieu Falce

- ▶ comparer 2 variances :
 - ▶ données : mesures sur 2 échantillons
 - ▶ exemple : une machine est-elle plus précise que l'autre ?
 - ▶ test de Fisher
- ▶ test de normalité d'une série de mesures :
 - ▶ données : mesures sur 1 échantillon
 - ▶ exemple : le TCL est-il vérifié dans ce cas ?
 - ▶ test de normalité (Shapiro-Wilk, ...) / test non paramétrique : Q-Q plot
- ▶ test pour valeurs extrêmes :
 - ▶ données : mesures sur 1 échantillon
 - ▶ exemple : cette mesure est-elle extrême ?
 - ▶ test de Dixon, test de Grubbs / test non paramétrique : Boxplot
- ▶ comparer une moyenne à une moyenne théorique :
 - ▶ données : mesures sur 1 échantillon / moyenne théorique

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Quel test statistique utiliser ? II

Matthieu Falce

- ▶ exemple : la durée de vie de mes ampoules est-elle conforme à la norme ?
- ▶ test de Student (aussi appelé t-test)
- ▶ comparer les moyennes de deux échantillons non appariés :
 - ▶ données : mesures sur 2 échantillons
 - ▶ exemple : en sortie d'école, les élèves de l'école A ont-ils un meilleur salaire que ceux de B ?
 - ▶ test de Student (aussi appelé t-test) / non paramétrique : Mann-Whitney
- ▶ comparer les moyennes de deux échantillons appariés :
 - ▶ données : plusieurs mesures sur un échantillon
 - ▶ exemple : de combien ce médicament fait-il baisser la fièvre ?
 - ▶ test de Student apparié / non paramétrique : Wilcoxon signé
- ▶ tester l'effet d'une ou plusieurs variables qualitatives sur une variable quantitative :

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Quel test statistique utiliser ? III

Matthieu Falce

- ▶ données : mesures sur plusieurs échantillons
 - ▶ exemple : l'école suivie a-t-elle un impact sur le salaire ?
 - ▶ ANOVA / non paramétrique : Kruskal-Wallis
- ▶ tester l'effet d'une ou plusieurs variables quantitatives sur une variable quantitative :
- ▶ données : mesurages de multiples grandeurs dans un échantillon
 - ▶ exemple : quel est l'effet de l'âge sur le rythme cardiaque moyen d'un athlète ?
 - ▶ régression linéaire
- ▶ comparer une proportion avec une proportion théorique :
- ▶ données : proportion observée avec son effectif / proportion théorique
 - ▶ exemple : les gauchers représentent-ils 14% de la population française ?
 - ▶ test du χ^2

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

Quel test statistique utiliser ? IV

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

Hypothèses

Risques d'erreur

Valeur p

Tests statistiques courants

Bestiaire

R

Références

- ▶ test d'indépendance de deux variables qualitatives :
 - ▶ données : tableau de contingence
 - ▶ exemple : les gens aux yeux bleus sont-ils jugés plus attirants ?
 - ▶ test du χ^2 d'indépendance

R

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

7- R

7.1. Introduction

R ?

Matthieu Falce

- ▶ R est un langage de programmation orienté statistiques
- ▶ open source
- ▶ multi-plateformes
- ▶ très utilisé dans l'analyse de données
 - ▶ recherche
 - ▶ industrie (banques, ...)

Comparable à :

- ▶ SAS
- ▶ Stata
- ▶ SPSS
- ▶ ...

Mais accessible gratuitement

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Pourquoi R ?

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Quand choisir R par rapport à Excel

- ▶ données à nettoyer
- ▶ grandes quantités de données
- ▶ besoin d'un langage de programmation (conditions / boucles)
- ▶ visualisation poussée et soignée
- ▶ présenter ses résultats de façon interactive sur un site web¹

1.<https://shiny.rstudio.com/>

Exemple et lancement

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

- ▶ on peut lancer la commande R dans un terminal pour avoir l'interpréteur
- ▶ on peut lancer la commande `Rscript mon_code.R` dans un terminal pour exécuter du code

Exemple et lancement

Matthieu Falce

- ▶ on peut lancer la commande R dans un terminal pour avoir l'interpréteur
- ▶ on peut lancer la commande Rscript mon_code.R dans un terminal pour exécuter du code

```
(mfalce@glados){15:27}~ ➔ R

R version 3.4.4 (2018-03-15) -- "Someone to Lean On"
Copyright (C) 2018 The R Foundation for Statistical Computing
Platform: x86_64-pc-linux-gnu (64-bit)

R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.

  Natural language support but running in an English locale

R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.

Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.

> 2+2
[1] 4
> □
```

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Introduction

Chargement et manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

**Chargement et
manipulation des données**

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

7- R

7.2. Chargement et manipulation des données

Types de données

Matthieu Falce

- ▶ scalaires (un élément)
- ▶ vecteurs (un ensemble d'éléments à une dimension)
 - ▶ un seul type d'éléments
 - ▶ si plusieurs types, ils sont castés dans le type le plus tolérant
- ▶ listes
 - ▶ type de conteneur le plus flexible du langage
 - ▶ permet de lier plusieurs éléments différents dans une seule variable
- ▶ matrices (ensemble d'éléments à deux dimensions)
 - ▶ utilisé pour les opérations mathématiques
 - ▶ même nombre d'éléments entre les colonnes
 - ▶ mêmes types d'éléments dans les colonnes
- ▶ *dataframes* plus général que les matrices, moins que les listes
 - ▶ pas de contrainte de type entre les colonnes
 - ▶ les éléments ne sont que des vecteurs
 - ▶ c'est ce qui est utilisé pour stocker des données

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Introduction

Chargement et manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Manipulation de données

Matthieu Falce

```
# variables
```

```
## Il y a deux types d'affectations
```

```
## avec un = et avec un <-
```

```
## les deux techniques sont équivalentes
```

```
## affectation 1
```

```
x = 2
```

```
y = x * 3
```

```
## affectation 2
```

```
x <- 3
```

```
y <- x * 3
```

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

**Chargement et
manipulation des données**

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Manipulation de données

Matthieu Falce

```
# calculs
```

```
2 + 2
```

```
3 * 4
```

```
1 / 2
```

```
3 ^ 3
```

```
# gestion des erreurs
```

```
1 / 0 + 1
```

```
## [1] Inf
```

```
# Vectorisation
```

```
## les opérations mathématiques marchent sur les
```

```
## scalaires et les conteneurs
```

```
xs = seq(-5, 5, 1/100)
```

```
ys = cos(xs ^ 2)
```

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

**Chargement et
manipulation des données**

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Manipulation de données

Matthieu Falce

```
## connaitre le type d'une variable
x = 2
class(x) # "numeric" (typeof(x) donne "double")

# vecteurs ATTENTION, l'indexation commence à 1

## déclaration
a = c(1, 2, 3)
b = 1:5 # equivalent à c(1, 2, 3, 4, 5)
c = seq(0, 1, 0.25) # de 0 à 1 par pas de 0.25

## accès à un élément
a[3]

## accès à un élément inexistant
a[4] # NA

## accès à un sous tableau
a[c(2, 3)]

## accès à des éléments ayant une propriété
nombres = 1:100
nombres_2 = -50:49
superieur_a_50 = nombres[nombres > 50]
tmp = nombres[nombres_2 > 0]
```

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Introduction

Chargement et manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Manipulation de données

Matthieu Falce

```
# listes
```

```
scores <- c(20,30,40,50)
```

```
student <- c("A","B","C","D")
```

```
sc_log <- c(TRUE,FALSE,FALSE,TRUE)
```

```
nb_students = 4
```

```
mylist <- list(nb_students, scores,student,sc_log)
```

```
## l'accès aux éléments se fait avec [[]]
```

```
mylist[[2]] # 20, 30, 40, 50
```

```
mylist[[2]][3] # 40
```

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

**Chargement et
manipulation des données**

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Manipulation de données

Matthieu Falce

```
# dataframes
```

```
# déclaration
```

```
d <- c(1,2,3,4)
```

```
e <- c("red", "white", "red", NA)
```

```
f <- c(TRUE,TRUE,TRUE,FALSE)
```

```
mydata <- data.frame(d,e,f)
```

```
## on peut changer le nom des colonnes
```

```
names(mydata) <- c("ID", "Color", "Passed")
```

```
## accès aux colonnes
```

```
mydata$ID # tous les éléments de la colonne ID
```

```
mydata[1] # tous les éléments de la colonne 1 (ID)
```

```
mydata[c(2, 3)] # dataframe avec les colonnes 2 et 3
```

```
mydata[, "ID"] # le vecteur avec les éléments de ID
```

```
## accès aux lignes
```

```
mydata[3, ]
```

```
mydata[c(1, 3, 4), ]
```

```
## accès à un élément
```

```
mydata[nb_ligne, nb_colonne]
```

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

**Chargement et
manipulation des données**

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Chargement de données

Matthieu Falce

```
# lecture de données tabulaires  
read.table(file_path, header = FALSE, sep = "",)  
  
## header : permet de dire d'utiliser la première  
# ligne comme nom des colonnes  
  
## sep : indique le type de séparateurs  
## ('', ' '; ' '/' '\t' ...)  
  
# données déjà présentes  
mtcar  
C02  
# ...
```

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

**Chargement et
manipulation des données**

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

7- R

7.3. Statistiques descriptives

Statistiques descriptives numériques

Matthieu Falce

```
a <- 1:100

# fonctions de descriptions
mean(a)
median(a)
var(a)
quantile(a) # par défaut quartiles
quantile(a, seq(0, 1, 0.01)) # décimale

# accès à un élément
q = quantile(a)
q[[1]]

# classification
classes = c(seq(0, 100, 25), Inf)
group = cut(a, classes, labels=FALSE)
a[group == 1]

# création de tables de contingences
table(mtcars$vs, mtcars$gear)
```

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Statistiques descriptives numériques

Matthieu Falce

```
# déclaration d'un data frame
```

```
a <- 1:100
```

```
b = 101:200
```

```
mydata <- data.frame(a, b)
```

```
# description globale
```

```
summary(mydata)
```

#	a	b
# Min. :	1.00	Min. :101.0
# 1st Qu.: 25.75		1st Qu.:125.8
# Median :	50.50	Median :150.5
# Mean :	50.50	Mean :150.5
# 3rd Qu.: 75.25		3rd Qu.:175.2
# Max. :	100.00	Max. :200.0

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Introduction

Chargement et manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

7- R

7.4. *Dataviz*

```
x = 1:10
y1 = x ^ 2
y2 = x ^ 3

# scatter plot
plot(x, y1)

# line plot
## interpolation entre les points
plot(x, y1, type="l")

## ajouter une série de données
plot(x, y1, type="b", col="red", pch=0)
lines(x, y2, col="blue", type="b", pch=1)

# rajouter un titre / une légende
title(main="Prévision croissance", col.main="green", font.main=4)
legend(
  "bottomright", legend=c("Pessimiste", "Optimiste"),
  col=c("red", "blue"), pch=0:1, lty=1
)

# scatter plot matrix
## utiliser la fonction pairs
```

[Concepts en statistique](#)[Démarche statistique](#)[Statistique Descriptive](#)[Statistique Inférentielle](#)[Modélisation linéaire](#)[Tests d'hypothèses](#)[R](#)[Introduction](#)[Chargement et manipulation des données](#)[Statistiques descriptives](#)[Dataviz](#)[Tests statistiques](#)[Bibliothèques tierces](#)[Références](#)

```
# barchart

# paramétrage
counts <- table(mtcars$gear)
barplot(
  counts, main="Car Distribution", horiz=TRUE,
  names.arg=c("3 Gears", "4 Gears", "5 Gears"))
)

# empiement
counts <- table(mtcars$vs, mtcars$gear)
barplot(counts, main="Car Distribution by Gears and VS",
  xlab="Number of Gears", col=c("darkblue","red"),
  legend = rownames(counts))

# cote à cote
barplot(counts, main="Car Distribution by Gears and VS",
  xlab="Number of Gears", col=c("darkblue","red"),
  legend = rownames(counts), beside=TRUE)
```

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Introduction

Chargement et manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

```
# histogrammes
hist(CO2$uptake)

# boxplot
boxplot(CO2$uptake)

## séparer les variables selon une variable qualitative
## "formula" : variable à expliquer ~ explicatrice
boxplot(
  mpg~cyl,data=mtcars, main="Car Milage Data",
  xlab="Number of Cylinders", ylab="Miles Per Gallon"
)

# pie
counts = table(CO2$Plant)
pie(counts)
```

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Introduction

Chargement et manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données
Statistiques descriptives

Dataviz

Tests statistiques
Bibliothèques tierces

Références

```
# créer une nouvelle figure (la fenêtre)
x11() # sous linux au moins

# layout, plusieurs plots cote à cote
par(mfrow=c(2, 2)) # 4 graphes, 2 * 2
par(mfrow=c(1, 4)) # 4 graphes, vertical 1 * 4

# sauvegarder une image
## il y a plusieurs formats d'enregistrement possibles

## A partir de zéro
png(filename="your/file/location/name.png")
plot(fit)
lines(...)
dev.off() # ferme et enregistre l'image

## En utilisant une image déjà affichée
dev.print(pdf, 'filename.pdf')
```

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

R est un outil très puissant pour la visualisation...
Des bibliothèques entières sont dédiées à la *dataviz*. La plus
connue / puissante est *ggplot*.

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

7- R

7.5. Tests statistiques

Tests statistiques

Matthieu Falce

```
x = rnorm(100, mean=5, sd=2)
```

```
# Test de student
```

```
t.test(x, mu=3, conf.level=0.99)
```

```
##           One Sample t-test
```

```
#
```

```
## data: x
```

```
## t = 9.3811, df = 99, p-value = 2.45e-15
```

```
## alternative hypothesis: true mean is not equal to 3
```

```
## 99 percent confidence interval:
```

```
## 4.369235 5.434021
```

```
## sample estimates:
```

```
## mean of x
```

```
## 4.901628
```

```
# récupérer les valeurs de l'intervalle de confiance
```

```
test_de_student = t.test(x, mu=3, conf.level=0.99)
```

```
test_de_student$conf.int
```

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives
Dataviz

Tests statistiques

Bibliothèques tierces

Références

Tests statistiques

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

```
# test de chi 2 de conformité

proportion_observee = c(20, 80)
proportion_attendue = c(25/100, 75/100)

chisq.test(proportion_observee, p=proportion_attendue)

##           Chi-squared test for given probabilities
##
## data:  proportion_observee
## X-squared = 1.3333, df = 1, p-value = 0.2482

c2 = chisq.test(proportion_observee, p=proportion_attendue)
c2$p.value
# [1] 0.2482131

# quel est H0 ?
# que pouvons-nous en conclure ?
```

Tests statistiques

Matthieu Falce

```
# test de chi 2 d'indépendance
```

```
# Table de contingence :
```

# Observé	cancer	non cancer	marge
# fumeur	342	258	600
# non fumeur	158	242	400
# marge	500	500	1000

```
fumeurs = c(342, 258)
```

```
non_fumeurs = c(158, 242)
```

```
# si on passe un vecteur, le test va croire que l'on
```

```
# compare des distributions entre elles
```

```
donnees = matrix(c(fumeurs, non_fumeurs), 2, 2, byrow=T)
```

```
chisq.test(donnees)
```

```
## Pearson's Chi-squared test with Yates'
```

```
## continuity correction
```

```
##
```

```
## data: donnees
```

```
## X-squared = 28.704, df = 1, p-value = 8.432e-08
```

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Tests statistiques

Matthieu Falce

```
# ANOVA

## La cylindrée a-t-elle un impact sur la consommation

## on fit le modèle
modele = aov(mpg ~ as.factor(cyl), data=mtcars)

## on effectue l'anova à proprement parler
anova(modele)

### Analysis of Variance Table
##
### Response: mpg
##          Df Sum Sq Mean Sq F value    Pr(>F)
### as.factor(cyl)  2  824.78   412.39   39.697 4.979e-09 ***
### Residuals      29  301.26    10.39
### ---
### Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

## regarder les graphes de diagnostique
par(mfrow=c(2, 2))
plot(modele)
```

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Introduction

Chargement et manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Tests statistiques

Matthieu Falce

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Introduction

Chargement et manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

```
# ANOVA

## La cylindrée a-t-elle un impact sur la consommation

## on fit le modèle
modele = aov(mpg ~ as.factor(cyl), data=mtcars)

TukeyHSD(x=modele, conf.level=0.95)
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = mpg ~ as.factor(cyl), data = mtcars)
##
## $`as.factor(cyl)`
##      diff      lwr      upr      p adj
## 6-4   -6.920779 -10.769350 -3.0722086 0.0003424
## 8-4  -11.563636 -14.770779 -8.3564942 0.0000000
## 8-6   -4.642857  -8.327583 -0.9581313 0.0112287
##

# on peut aussi visualiser les différences
plot(TukeyHSD(x=modele, conf.level=0.95))

# Que peut-on en conclure ?
```

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Introduction

Chargement et
manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

7- R

7.6. Bibliothèques tierces

Bibliothèques tierces

Matthieu Falce

```
# on installe la bibliotheque agricolae
# à ne faire qu'une seule fois, depuis R
# install.packages s'occupe du téléchargement,
# compilation et installation du paquet
install.packages("agricolae")

# on charge la bibliotheque agricolae
library(agricolae)

# HSD.test à besoin d'un modèle avec les noms qui sont des colonnes
mtcars$fcyl = as.factor(mtcars$cyl)
modele = aov(mpg ~ fcyl, data=mtcars)

# on utilise une fonction de cette bibliothèque
HSD.test(modele, 'fcyl', console=T)

## Study: modele ~ "fcyl"
## HSD Test for mpg
## Mean Square Error: 10.38837
## ...
## Treatments with the same letter are not significantly different.
##      mpg groups
## 4 26.66364      a
## 6 19.74286      b
## 8 15.10000      c
```

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Introduction

Chargement et manipulation des données

Statistiques descriptives

Dataviz

Tests statistiques

Bibliothèques tierces

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Références

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

8- Références

8.1. Concepts en statistique

Références : concepts

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Types de statistiques :

- ▶ support.minitab.com
- ▶ astro.ulg.ac.be

Introduction :

- ▶ math.univ-lille1.fr

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

8- Références

8.2. Démarche statistique

Références : démarche I

Matthieu Falce

- ▶ cerim.univ-lille2.fr
- ▶ help.xlstat.com
- ▶ pbil.univ-lyon1.fr
- ▶ jybaudot.fr

Intervalles de prédiction / confiance :

- ▶ minitab.com
- ▶ foucart.thierry.free.fr
- ▶ gerad.ca

Échantillonnage :

- ▶ fr.khanacademy.org
- ▶ accountingtools.com

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

8- Références

8.3. Statistique descriptive

Références : statistique descriptive I

Matthieu Falce

Type de statistiques :

- ▶ Wikipédia : Statistique descriptive
- ▶ support.minitab.com
- ▶ astro.ulg.ac.be

Généralités :

- ▶ math.univ-lille1.fr
- ▶ insee.fr
- ▶ <https://support.office.com/fr-fr>
- ▶ matrices de variances / covariances - corrélations : math.unice.fr

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Références : statistique descriptive II

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Dataviz :

- ▶ Wikipédia : Représentation graphique de données
- ▶ apiacoa.org
- ▶ peltiertech.com

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

8- Références

8.4. Inférence et tests

Références : inférence et tests I

Matthieu Falce

Respect des hypothèses

- ▶ Lise Vaudor : non-respect des hypothèses du modèle linéaire

Choix du modèle / test

- ▶ help.xlstat.com
- ▶ cons-dev.org
- ▶ Wikipédia : Table d'utilisation des tests statistiques

Intervalle de confiance

- ▶ support.microsoft.com
- ▶ Wikipédia : Intervalle de confiance
- ▶ Wikipédia : Variance (statistiques et probabilités)
- ▶ Wikipédia : Loi de Student
- ▶ math.univ-toulouse.fr
- ▶ math.univ-toulouse.fr

Concepts en statistique

Démarche statistique

Statistique Descriptive

Statistique Inférentielle

Modélisation linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Références : inférence et tests II

- ▶ Wikiversité : Intervalle de confiance d'une fréquence

Tailles d'échantillons

- ▶ fr.wikihow.com
- ▶ Wikipédia : Échantillon (statistiques)
- ▶ blog.questio.fr
- ▶ fr.surveymonkey.com
- ▶ marges d'erreurs sur les sondages et les tailles d'échantillons
 - ▶ Wikipédia : Sondage d'opinion
 - ▶ publicsenat.fr
 - ▶ ifop.com

Lois

- ▶ astro.ulg.ac.be
- ▶ statisticshowto.datasciencecentral.com
- ▶ <http://www.jybaudot.fr/Probas/tcl.html>

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Références : inférence et tests III

- ▶ Wikipédia : Loi normale
- ▶ Wikipédia : Théorème central limite
- ▶ statisticsbyjim.com

QQ Plot :

- ▶ Wikipédia : Diagramme Quantile-Quantile

Cours régression + R

- ▶ emse.fr
- ▶ pbil.univ-lyon1.fr

Tests :

- ▶ Wikipédia : Test du χ^2
- ▶ sthda.com
- ▶ exo7.emath.fr
- ▶ bdesgraupes.pagesperso-orange.fr

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Références : inférence et tests IV

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

► lmpt.univ-tours.fr

► univ-montp3.fr

Cours complets :

► unilim.fr

► math.agrocampus-ouest.fr

► chups.jussieu.fr

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

8- Références

8.5. Modélisation linéaire

Références : modélisation linéaire

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Régression linéaire, résidus, prédiction :

- ▶ gerad.ca
- ▶ jybaudot.fr
- ▶ perso.ens-lyon.fr

Intervalles de confiance, de prédiction, de tolérance :

- ▶ blog.minitab.com : Quelles sont les différences entre intervalles de confiance, de prédiction ou de tolérance ?

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

8- Références

8.6. R

Références : R I

Matthieu Falce

Généralités :

- ▶ <https://www.r-project.org/about.html>
- ▶ rforexcelusers.com
- ▶ rdocumentation.org
- ▶ stat.ethz.ch
- ▶ burns-stat.com

Tests :

- ▶ r-bloggers.com
- ▶ mehdikhaneboubi.free.fr
- ▶ sites.google.com
- ▶ larmarange.github.io

Lois statistiques :

- ▶ <http://seankross.com/notes/dpqr/>

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Références : R II

Matthieu Falce

Concepts en
statistique

Démarche
statistique

Statistique
Descriptive

Statistique
Inférentielle

Modélisation
linéaire

Tests d'hypothèses

R

Références

Concepts en statistique

Démarche statistique

Statistique descriptive

Inférence et tests

Modélisation linéaire

R

Plotting :

- ▶ stackoverflow.com
- ▶ statmethods.net
- ▶ <https://www.harding.edu/fmccown/r/>